

다중객체추적 데이터 연관에서 검출 불확실성은 활용 가능한가

*Is Detection Uncertainty Usable for Data Association
in Multi-Object Tracking?*

12241701 박준형

인하대학교 데이터사이언스학과

2026년

요 약

다중객체추적(Multi-Object Tracking, MOT)의 데이터 연관은 트랙과 검출 사이의 비용 행렬을 만들고 헵가리안 알고리즘으로 푸는 방식이 표준이다. 이 비용에 검출기가 제공하는 위치 불확실성을 넣으면 성능이 개선될 것이라는 기대가 있어 왔으나, 보고된 결과는 일관되지 않다. 본 연구는 MOT17에서 검출 결과를 캐시로 고정하여 비교군 사이에서 비트 단위로 같게 유지한 채, 검출 불확실성 σ 를 네 경로 — 칼만 필터 측정잡음, 거리 함수, 게이팅, 매칭 임계값 — 에 주입하고 두 가지 추정 방식(NMS 후보 분산, DFL 분포 분산)을 같은 절차로 비교하였다.

결론을 먼저 적는다. 검출기가 산출한 σ 의 순위 정보는 검출 품질에 대한 것이며 연관 판단으로는 거의 옮겨가지 않는다. 그리고 이 판정은 무엇으로 재는가에 달려 있다.

주 주장은 검출 수준에 있다. σ 는 위치 오차를 예측한다. 박스 높이를 통제된 편상관계수 중앙값이 NMS 후보 분산에서 +0.322이고 7개 시퀀스 전부가 양수이다. 그럼에도 확률 모형으로는 박스 크기에 비례하는 모형에 7개 시퀀스 전부에서 패배하였다(양측 부호검정 $p = 0.0156$). 자유도를 제약 없이 적합한 Student- t 에서도, 컨포멀 보정으로 커버리지를 96.1%까지 올린 뒤에도 결과가 같았으므로 원인은 꼬리도 스케일도 아니다. 둘을 합친 모형은 크기 모형을 7/7로 이기나 그 폭이 크기가 σ 를 이긴 폭의 1/47에 불과하다. 단 이 패배는 NMS 후보 분산에 대한 것이며, DFL 분포 분산은 방향이 반대였다(6/7, 유의성 미달).

추적 수준 결과는 7개 장면에 대한 기술로 제시한다. 네 경로가 모두 음의 결과였으나 ($-0.21 \sim -8.90$) 넷을 같은 무게로 세어서는 안 된다 — 둘은 본 연구의 최소 검출 가능 효과(3.31 HOTA)보다 작아 0과 구별되지 않는다. 이득 쪽으로 해상도를 넘은 경로는 없었다. 그것이 “개선할 것이 없어서”인지 가리기 위해 연관 오라클 여지를 측정하였다. 검출을 고정한 채 1단계 연관만 정답으로 해결하면 +3.122 HOTA를 얻으므로 여지 자체는 존재한다. 그 여지에 σ 가 닿는지도 직접 물었다. 수정 가능한 연관 오류에 대한 AUC는 DFL 0.46, NMS 0.54로 쌍의 독립을 가정하면 둘 다 사전 등록한 기준 0.55 아래이나, 시퀀스 군집을 반영하면 NMS는 그 판정이 서지 않는다(상한 0.69).

그리고 이 결과들은 측정 방식에 달려 있다. 헵가리안이 실제로 푸는 형태 — 같은 호출 안에서 정답 검출과 오답 검출을 짝지어 비교하는 것 — 로 재면 박스 크기는 정답을 64.5%로 고른다. 채택된 쌍 전체의 주변부 AUC로는 0.47로 무용해 보이던 신호이다. 두 값은 같은 형태의 확률인데 우연 수준의 반대쪽에 놓인다. 비교 대상만 다르다(5.7절). 반면 검출기 σ 는 어느 방식으로 측정해도 0.5 아래이다. 다만 박스 크기의 이 관측은 탐색적이다. 시퀀스 군집을 반영하면 구간이 0.5를 포함하고 7개 시퀀스 중 넘은 것은 4개이다. 따라서 본 연구의 실질적 권고는 결과가 아니라 순서에 있다. 주입 형태를 설계하기 전에 오라클 여지와 행 조건부 판별력을 먼저 측정하라 — 둘 다 추적기 재생 한 번씩이면 되며, 본 연구는 그 반대 순서로 진행하였다.

부수적으로, 검출별 스칼라를 비용에 덧셈으로 넣으면 최적 할당이 바뀌지 않음을

실제 데이터에서 확인하였다. 할당이 달라진 12건은 전부 동점이었고 최적성 위배는 0건이다. 이는 문헌이 예외 없이 곱셈 형태를 사용해 온 사실을 설명한다. 끝으로 σ 에 예측력이 전혀 없다고 단언하지는 않는다. 장면 간 편차가 크고, 분석에서 제외한 오탐쌍에 대해서는 약한 신호가 관찰되었기 때문이다.

핵심어: 다중객체추적, 데이터 연관, 검출 불확실성, 연관 오라클 여지, 음의 결과, 사전 등록

본 연구는 사전 등록된 실험 계획, 재현 가능한 캐시 기반 실험 설계, 그리고 18건의 철회 기록을 함께 공개한다. 코드와 실험 기록은 <https://github.com/JunHyeong-data/MOT-Assoc>에서 확인할 수 있다.

Abstract

Data association in multi-object tracking (MOT) is standardly posed as a cost matrix between tracks and detections and solved with the Hungarian algorithm. It has long been expected that injecting the *localization uncertainty* produced by the detector into this cost would improve tracking, yet reported results are inconsistent. This work tests that expectation on MOT17 under controlled conditions: detections are cached so that every condition replays a bit-identical set, and the uncertainty σ is injected through four channels — Kalman filter measurement noise, the distance function, gating, and the matching threshold — with two estimation methods (NMS candidate spread, DFL distribution variance) compared under the same procedure.

The conclusion is stated first. **The rank information carried by detector-produced σ is about detection quality and transfers only weakly to association decisions, and this verdict depends on how it is measured.**

The primary claim is at the detection level. σ does predict localization error (partial correlation controlling for box height, median +0.322, positive in all seven sequences), yet as a probabilistic model it loses to a simple box-size model in all seven sequences (two-sided sign test $p = 0.0156$), and this holds under a Student- t family fitted to the lower bound of the degrees-of-freedom grid and after conformal recalibration raises coverage to 96.1%. At the tracking level — reported descriptively for these seven scenes — all four channels are negative, but they should not be weighted equally: two fall below the minimum detectable effect of this design (3.31 HOTA) and are indistinguishable from zero. An association oracle shows that headroom does exist (+3.122 HOTA when only the first association stage is solved with ground truth), so “there was nothing to gain” is rejected. Whether σ can reach that headroom was measured directly: the AUC for correctable association errors is 0.4571 (DFL) and 0.5355 (NMS), both below the preregistered threshold of 0.55 under an independence assumption, though the NMS verdict does not survive a sequence-cluster bootstrap.

Finally, the measurement itself matters. Scored the way the Hungarian algorithm actually asks — pairing the correct and the wrongly matched detection inside the same call — box size selects the correct detection 64.5% of the time, whereas the marginal AUC over all accepted pairs makes the same signal look useless (0.4661). **The two numbers are probabilities of the same form on opposite sides of chance; only the comparison set differs.** Detector σ stays below 0.5 under either. The practical recommendation of this work is therefore about order rather than outcome: measure the oracle headroom and the row-conditional discriminability *before* designing an injection form. Each costs one tracker replay; this study proceeded in the opposite order.

Keywords: multi-object tracking, data association, detection uncertainty, association oracle headroom, negative results, preregistration

목 차

요약	1
Abstract	3
1 서론	7
2 관련 연구	9
2.1 신호의 추정 방식과 적용 경로	9
2.2 두 축의 구체적 형태	9
2.3 비용 함수의 형태에 대한 관찰	11
2.4 오라클 분석: 이 논문이 빌려 쓰는 도구	11
2.5 공분산 역설에 대한 기존 대응	12
3 데이터 및 실험 환경	13
3.1 데이터	13
3.2 검출 결과의 고정	13
3.3 추적기와 알려진 구현 문제	14
3.4 검출 불확실성의 산출	14
3.5 탐색적 분석: σ 의 스케일 특성	15
4 방법론	16
4.1 설계 제약: 덧셈은 할당에 영향을 주지 않는다	16
4.2 비교 조건	17
4.3 연관 오라클 여지	17
4.4 연관 오류에 대한 σ 의 예측력 측정	18
4.5 평가지표	19
5 실험 및 결과	20
5.1 검출 수준: σ 는 위치 오차를 예측한다	20
5.2 검출 수준: NMS 후보 분산은 박스 크기를 대체하지 못한다	21
5.3 추적 수준: 네 경로 모두 음의 결과	23
5.4 격자와 게이팅 대조군: 우열은 무엇을 맞추었는가에 달려 있다	24
5.5 추적 수준: 덧셈과 곱셈의 실측 비교	26
5.6 추적 수준: 개선 여지는 존재하는가	27
5.7 추적 수준: σ 는 그 여지에 도달할 수 있는가	28

6	분석: 왜 도달하지 못하는가	33
6.1	네 경로의 음의 결과에 대한 재해석	33
6.2	같은 경로, 다른 추정 방식: 문헌의 성패에 대한 설명	33
6.3	개선 여지는 어디에 있는가: MOT17-13 분석	34
6.4	NMS 후보 분산의 장면 간 산포 — 설명하지 못하였다	35
6.5	표본 크기에 대한 분석	36
7	결론	38
7.1	요약	38
7.2	제안: 신호에 투자하기 전에 측정하는 절차	39
7.3	한계	40
7.4	향후 과제	42
7.5	재현성	43
A	조건별 통제와 남은 취약점	45
B	게이팅 대조군의 맞춤 기준	48
C	장면 간 산포에 대해 시험한 가설	50

Chapter 1

서론

다중객체추적은 매 프레임에서 검출된 객체를 기존 트랙에 연결하는 작업이다. 표준적인 접근인 tracking-by-detection 방식에서 이 연결은 트랙 M 개와 검출 N 개 사이의 비용 행렬을 구성하고 헝가리안 알고리즘(Kuhn, 1955)으로 최적 할당을 구하는 방식으로 이루어진다. SORT(Bewley et al., 2016)는 이 비용으로 IoU를 사용하였고, DeepSORT(Wojke et al., 2017)는 마할라노비스 거리와 외형 특징을 결합하였으며, ByteTrack(Zhang et al., 2022)은 IoU를 유지하되 낮은 점수의 검출까지 2단계로 활용하였다.

이 비용 행렬에 검출기가 제공하는 위치 불확실성을 반영하면 성능이 개선되리라는 기대는 자연스럽다. 검출기가 어떤 박스의 위치를 확신하지 못한다면, 그 정보는 연관 판단에 유용해야 한다는 직관이다. 실제로 이 방향의 시도가 여럿 있었다. UTrack(Solano-Carrillo et al., 2024)은 NMS 후보들의 분산을 검출 불확실성으로 삼아 칼만 필터에 전파하였고, UncertaintyTrack(Lee and Waslander, 2024)은 검출기가 직접 예측한 공분산을 사용하였다.

그러나 보고된 결과는 기대와 다르다. UncertaintyTrack의 저자들은 자신들의 어블레이션 실험에서 칼만 필터 측정잡음 교체가 단독으로는 성능을 떨어뜨린다고 명시하였으며, 그 원인에 대해 다음과 같이 기술하였다.

“It is possible that the multivariate Gaussian distribution does not accurately represent the true underlying uncertainty distribution, suggesting that the uncertainty estimates might not be compatible with the Kalman Filter. *This remains an area for future investigation.*”(Lee and Waslander, 2024)

즉 원인은 추측으로 남아 있다. 본 연구는 이 물음에 측정값을 넣는 것을 목표로 한다. 주목할 점은 이 문제가 최근에 제기된 것이 아니라는 사실이다. DeepSORT는 2017년에 이미 매칭 캐스케이드를 도입하면서 그 동기를 다음과 같이 밝혔다.

“When two tracks compete for the same detection, the Mahalanobis distance favors larger uncertainty ... This is an undesired behavior as it can lead to increased track fragmentations and unstable tracks.”(Wojke et al., 2017)

이는 본 연구가 공분산 역설이라 부르는 현상 — 불확실성이 클수록 마할라노비스 거리가 작아져 오히려 선호되는 구조 — 을 정확히 지적한 것이다. DeepSORT는 이를 비용 함수를 수정하는 대신 트랙 나이 순서의 캐스케이드로 우회하였다. 이후 UCMCTrack(Yi et al., 2024)이 거리에 로그 행렬식 항을 더해 이 편향을 억제하는 방법을 제시하였다(2.5절). 그러나 두 대응 모두 불확실성을 무엇으로 재는가는 건드리지 않는다. 전자는 순

서로 피해 가고, 후자는 별점을 더할 뿐이다. 검출기가 산출한 불확실성이 연관에 쓸모가 있는지 자체를 통제된 조건에서 측정한 연구는 찾기 어렵다.

본 연구의 기여는 다음 네 가지이다.

첫째, 검출 불확실성이 데이터 연관에 도달하는지를 통제된 조건에서 측정한다. 검출 결과를 캐시로 고정하여 비교군 사이에서 비트 단위로 동일하게 유지하고, 적용 경로만을 변화시켜 그 효과를 분리한다. 두 가지 추정 방식과 네 가지 적용 경로를 같은 절차로 비교한다.

둘째, 연관 오라클 분석을 이 질문에 적용한다. 검출을 고정한 채 1단계 연관만 정답으로 해결하여 “이 데이터에서 연관이 개선할 수 있는 여지”를 직접 쟁다. 이는 음의 결과를 해석하는 데 필수적이다. “방법이 나뻤다”와 “개선할 것이 없었다”를 가르려면 이 값이 있어야 하기 때문이다. 다만 이 분석 자체는 본 연구의 고안이 아니다. 오라클로 한 성분만 정답으로 바꾸고 그 차이를 귀속하는 방법은 검출 분야의 TIDE(Bolya et al., 2020)에서 정립되었고, 추적에서는 Tracktor(Bergmann et al., 2019), DanceTrack(Sun et al., 2022), MeNToS(Miah et al., 2023), CAMELTrack(Somers et al., 2025)이 이미 사용하였다(2.4절). 본 연구가 더한 것은 1단계로 범위를 한정된 것과 그 이득을 AssA/DetA로 귀속한 것이며, 이는 도구의 세부이지 독립적인 기여가 아니다.

셋째, 신호가 실제로 쓸모 있는지를 적용 경로와 무관하게 직접 쟁다. 오라클로 어느 연관 결정이 틀렸는지 알 수 있으므로, 어떤 형태로 넣을지 정하기 전에 “이 신호가 연관 오류를 구별하는가”를 물을 수 있다. 7.2절에서 이를 사전 점검 절차로 정리한다.

넷째, 설계 제약을 실제 데이터에서 확인한다. 검출별 스칼라를 비용에 어떤 형태로 넣어야 하는지에 대한 제약을 유도하고, 실측으로 검증한다.

논문의 구성은 다음과 같다. 2장에서 관련 연구를 검토하고 신호의 추정 방식과 적용 경로라는 두 축으로 정리한다. 3장에서 데이터와 실험 환경을 기술하며, 4장에서 설계 제약과 비교 방법, 평가지표를 정의한다. 5장에서 실험 결과를 검출 수준과 추적 수준으로 나누어 제시하고, 6장에서 원인을 분석한다. 7장에서 결론과 한계를 논의한다.

Chapter 2

관련 연구

2.1 신호의 추정 방식과 적용 경로

검출 불확실성을 데이터 연관에 활용하는 연구는 두 가지 축으로 정리할 수 있다. 하나는 신호를 어디서 얻는가(추정 방식)이고, 다른 하나는 그 신호를 어디에 넣는가(적용 경로)이다. 본 연구는 이 두 축을 분리하여 보는 것이 문헌의 성패를 이해하는 데 핵심이라고 본다. 표 2.1에 주요 방법들을 추정 방식으로 묶어 정리하였다.

표를 세로로 읽으면 패턴이 보인다. 박스 크기와 검출 신뢰도를 사용한 방법들은 이득을 보고한 반면, 검출기가 산출한 σ 를 사용한 항목은 게이팅과 연관 순서 둘을 제외하면 모두 손실이다. 특히 칼만 필터 측정잡음이라는 같은 경로에서도 결과가 갈린다. 박스 크기를 넣은 UCMCTrack은 SOTA를 달성하였고, 검출기 σ 를 넣은 두 연구는 모두 손실을 보고하였다. 6.2절에서 이 패턴에 대한 설명을 제시한다.

표에 없는 조합도 정보이다. 본 연구가 확인한 범위에서 박스 크기를 연관 순서에 사용한 사례나 검출 신뢰도를 게이팅에 사용한 사례는 없었다. 또한 검출별 스칼라를 비용에 덧셈으로 넣은 사례가 본 연구 외에 하나도 없다 — 4.1절에서 그 이유를 설명한다. “검출별”이라는 한정이 필요하다. 쌍에 의존하는 항을 더하는 사례는 있으며(OC-SORT의 OCM), 그것은 이 관찰의 반례가 아니다(4.1절).

2.2 두 축의 구체적 형태

무엇을 불확실성으로 삼는가 가장 널리 쓰이는 것은 박스 크기를 대리 변수로 쓰는 방식이다. NWD(Wang et al., 2021)는 바운딩 박스를 2차원 가우시안으로 보고 $\Sigma = \text{diag}(w^2/4, h^2/4)$ 를, UCMCTrack(Yi et al., 2024)은 칼만 필터의 측정잡음을 $R_{uv} = \text{diag}((\sigma_m w)^2, (\sigma_m h)^2)$ 로 정의한다(여기서 σ_m 은 하이퍼파라미터이고 w, h 는 검출된 박스의 폭과 높이이다). 검출 신뢰도를 쓰는 NSA Kalman(Du et al., 2023)은 신뢰도 c 로 $\tilde{R} = (1 - c)R$ 을 조정한다. 셋 다 검출기가 산출한 불확실성이 아니다. 검출기가 산출한 σ 를 쓰는 것은 둘인데, UTrack(Solano-Carrillo et al., 2024)은 NMS에서 억제된 후보 박스들의 중심 분산을 검출기 구조 변경 없이 추론 이후에 측정하고, UncertaintyTrack(Lee and Waslander, 2024)은 검출기가 분포 매개변수를 직접 예측하도록 학습시킨다. GFLv2(Li et al., 2021)는 DFL(Distribution Focal Loss) 분포의 통계량으로 위치 품질을 예측하였으나 추적으로 확장하지는 않았다.

표 2.1: 검출 불확실성을 데이터 연관에 넣은 방법들. 추정 방식으로 묶어 정렬하였다. 보고된 결과의 단위가 서로 달라(HOTA, mMOTA, AP) 하나의 축에 올릴 수 없으므로 원문의 표현을 그대로 옮겼다. 모든 항목은 원문을 직접 확인하였다. 기울임체는 본 연구의 측정값이다.

방법	적용 경로	보고/측정된 결과	출처
추정 방식: 박스 크기(기하)			
UCMCTrack	칼만 필터 R	SOTA 달성	(Yi et al., 2024)
NWD	거리 함수	검출 과제에서 이득(추적 아님)	(Wang et al., 2021)
본 연구 (대조군)	거리 함수	-4.98 (검출기 σ 보다 3.93 우수)	5.3절
본 연구 (대조군)	게이팅	검출기 σ 보다 우수 — 크기는 맞춤 기준 의존	5.4절
추정 방식: 검출 신뢰도			
NSA	칼만 필터 R	채택됨	(Du et al., 2023)
Kalman			
ByteTrack 구현	비용 곱셈	논문에 근거 없음	2.3절
추정 방식: 위치 품질			
LG-Track	비용 곱셈	이득 보고(식 1, 3)	(Meng et al., 2025)
LG-Track	연관 순서	4단계 캐스케이드	(Meng et al., 2025)
추정 방식: 검출기 산출 σ			
UTrack	칼만 필터 R	본 연구 재현 -0.62	(Solano-Carrillo et al., 2024)
UncertaintyTrack	칼만 필터 R	저자 보고 -0.1	(Lee and Waslander, 2024)
UncertaintyTrack	게이팅	저자 보고 mMOTA +2.2	(Lee and Waslander, 2024)
UncertaintyTrack	연관 순서	저자 보고 +0.1	(Lee and Waslander, 2024)
본 연구	비용 덧셈	-3.75	5.5절
본 연구	비용 곱셈	-1.01	5.5절
본 연구	거리 함수	-8.90	5.3절
본 연구	게이팅	-4.33	5.3절
본 연구	매칭 임계값	-0.21 (오라클 +0.89)	5.3절
추정 방식: 트랙 쪽 이력			
DeepSORT	연관 순서	매칭 캐스케이드	(Wojke et al., 2017)
Bae와 Yoon	연관 순서 (라우팅)	이득 보고	(Bae and Yoon, 2014)

어디에 넣는가 칼만 필터 측정잡음이 가장 많이 시도된 경로이며 위에서 언급한 넷이 모두 여기에 해당한다. 거리 함수는 IoU를 분포 간 거리로 대체하는 접근으로 NWD가 대표적이며, UCMCTrack은 정규화된 마할라노비스 거리 $D = \epsilon^T S^{-1} \epsilon + \ln |S|$ 를 사용한다. 여기서 로그 행렬식 항은 공분산 역설을 억제하기 위한 것이다(2.4절). 게이팅은 불확실성에 비례하여 박스를 키워 겹침 확률을 높이는 방식으로, UncertaintyTrack의 어블레이션에서 단일 최대 기여를 보였다(mMOTA +2.2, mIDF1 +3.0). 연관 순서와 라우팅은 DeepSORT의 트랙 나이 캐스케이드와 Bae와 Yoon(Bae and Yoon, 2014)의 tracklet confidence 분기처럼 대개 트랙 쪽 양을 쓰며, 검출 쪽 신호를 쓴 사례는 LG-Track(Meng et al., 2025)의 4단계 캐스케이드와 UncertaintyTrack의 엔트로피 기반 그리디 매칭이다.

2.3 비용 함수의 형태에 대한 관찰

원문을 검토한 결과 한 가지 규칙성이 관찰된다. 문헌이 검출별 스칼라를 비용에 넣을 때는 예외 없이 곱셈 형태를 사용한다. LG-Track은 $C_1 = C_{\text{iou}} \cdot d_l$, $C_3 = C_{\text{cos}} \cdot d_s$ 의 형태를 사용하고, ByteTrack 구현체는 $\text{cost} = 1 - \text{IoU} \cdot s$ 를 사용한다. 덧셈 형태를 사용한 사례는 찾을 수 없었다.

주목할 점은 이 형태를 선택한 이유를 밝힌 문헌이 없다는 것이다. 특히 ByteTrack의 경우, 본 연구가 논문 전문(64,480자)을 검색한 결과 점수를 비용에 곱하는 식이 **논문에 존재하지 않는다**. 논문에서 검출 점수는 높음과 낮음을 나누는 기준으로만 사용되며, 유사도는 “IoU 또는 Re-ID 특징 거리”로 기술된다. $\text{cost} = 1 - \text{IoU} \cdot s$ 는 구현체에만 존재하는 설계이다. 4.1절에서 이 형태가 왜 필연적인지에 대한 설명을 제시한다.

2.4 오라클 분석: 이 논문이 빌려 쓰는 도구

본 연구는 4.3절에서 연관 오라클 분석을 사용한다. 이 방법은 본 연구의 고안이 아니므로 출처를 밝힌다.

한 성분만 정답으로 바꾸고 지표의 변화를 그 성분에 귀속하는 방식은 검출 분야의 TIDE(Bolya et al., 2020)에서 체계화되었다. 추적에서는 Tracktor(Bergmann et al., 2019)가 검출을 고정된 채 재식별을 정답으로 대체하는 Oracle-reID를 보고하였고, DanceTrack(Sun et al., 2022)은 반대 방향으로 정답 박스를 검출 대신 넣고 연관 방법을 비교하여 “무엇이 병목인가”를 물었다. MeNToS(Miah et al., 2023)는 검출과 단기 연관을 고정하고 장기 연관만 정답 ID로 대체하여 HOTA 여지를 보고하였으며, CAMELTrack(Somers et al., 2025)은 “Association Oracle”이라는 이름으로 검출을 유지한 채 정답 ID를 물려주는 실험을 보고하였다.

따라서 본 연구의 오라클은 새로운 방법이 아니라 확립된 분석의 적용이다. 두 가지 세부만 다르다. 첫째, 본 연구는 1단계 연관만 오라클로 풀고 2~3단계와 트랙 관리는 그대로 둔다. 이는 여지를 더 작게 만드는 방향이므로 보수적이다. 둘째, 정답 박스를 검출 대신 넣지 않고 실제 검출을 그대로 유지한다. 정답 박스를 넣으면 오탐과 미검출이

사라져 연관 문제 자체가 쉬워지므로, 실제 배포 조건에서의 여지를 측정하려면 검출을 건드리지 않아야 한다. 5.6절에서 이 차이가 실제로 크다는 것을 보인다. 여지의 24.7%가 오탐 행이 출력에서 빠지는 데서 온다.

2.5 공분산 역설에 대한 기존 대응

가림(occlusion) 구간에서 트랙의 공분산이 커지면 마할라노비스 거리가 작아져 오히려 매칭이 선호되는 현상이 발생한다. 이에 대한 대응은 세 갈래로 나뉜다. DeepSORT는 캐스케이드로 우회하였고, UCMCTrack은 로그 행렬식 항을 추가하여 억제하였다. OC-SORT(Cao et al., 2023)는 다른 문제를 다룬다. 관측이 없는 동안 상태 추정의 오차가 시간에 따라 증폭되는 현상(temporal error magnification)에 대응하며, 논문 본문에서 “uncertainty”라는 용어를 사용하지 않는다. 즉 가림 구간에서 발생하는 두 가지 실패 — 평균의 표류와 공분산의 팽창 — 중 전자를 다룬 것이다.

Chapter 3

데이터 및 실험 환경

3.1 데이터

실험에는 MOT17(Milan et al., 2016) 학습 분할의 7개 시퀀스를 사용하였다. 각 시퀀스의 후반부 절반을 검증용으로 분리하는 val_half 방식을 따랐으며, 이는 UTrack의 재현 실험과 조건을 맞추기 위한 선택이다. 시퀀스별 특성은 표 3.1와 같다.

표 3.1: MOT17 val_half 시퀀스 특성. 카메라 움직임은 연속 프레임에서 동일 객체 중심 이동의 중앙값이다. 본문의 “약 3.8배”는 MOT17-13(9.22)을 나머지 여섯 시퀀스의 중앙값(2.46)과 견준 값이다. 평균(1.94) 기준이면 4.8배가 된다.

시퀀스	fps	해상도	프레임당 객체	카메라 움직임(px)	연속 IoU
MOT17-02	30	1920×1080	33.0	0.00	0.985
MOT17-04	30	1920×1080	46.1	0.00	0.986
MOT17-05	14	640×480	8.0	2.92	0.890
MOT17-09	30	1920×1080	11.0	3.50	0.923
MOT17-10	30	1920×1080	18.2	2.00	0.886
MOT17-11	30	1920×1080	10.1	3.20	0.936
MOT17-13	25	1920×1080	8.4	9.22	0.572

MOT17-13은 카메라 움직임이 나머지의 약 3.8배로 두드러진다. 이 시퀀스는 이후 여러 지표에서 특이값을 보이므로 6.3절에서 별도로 분석한다.

3.2 검출 결과의 고정

본 연구의 핵심 통제는 모든 비교군이 완전히 동일한 검출 결과를 사용하도록 만드는 것이다. 검출기를 매번 실행하면 조건 간 차이에 검출 변동이 섞이게 되므로, 검출 결과를 한 번 산출하여 npz 파일로 저장하고 이후 모든 실험이 이를 재생하는 방식을 택하였다.

검출기는 UTrack이 공개한 가중치(ablation_17_best.pt)를 사용하였고, 입력 크기 800×1440, 신뢰도 임계값 0.01, NMS IoU 0.70으로 고정하였다. 7개 시퀀스의 val_half 구간은 합계 2,652 프레임이며, 산출된 검출은 합계 63,137건이다.

이 설계의 이점은 두 가지이다. 첫째, 조건 간 검출이 비트 단위로 동일하므로 성능 차이를 연관 방식의 차이로 온전히 귀속할 수 있다. 둘째, 추적기 재생이 결정적이므로 실험 간 변동이 존재하지 않는다. 실제로 동일 조건을 처음부터 다시 재생하여 출력 파일의 해시를 대조한 결과 7개 시퀀스 전부에서 비트 단위로 일치하였다.

3.3 추적기와 알려진 구현 문제

추적기는 ultralytics 8.4.46의 ByteTrack 구현을 사용하고, 1단계 연관의 비용 계산 부분만 교체하였다. 하이퍼파라미터는 모든 조건에서 다음과 같이 고정하였다. 1단계 검출 임계값 0.25, 2단계 하한 0.1, 신규 트랙 생성 임계값 0.25, 트랙 버퍼 30프레임, 1단계 매칭 임계값 0.8(즉 $\text{IoU} \geq 0.2$), fuse_score 활성화. 매칭 임계값을 다루는 조건(5.3절)을 제외하면 이 값들은 어느 조건에서도 바뀌지 않는다. 한편 이 구현에는 알려진 문제가 있다. 2단계 연관에서 fuse_score가 적용되어 비용이 $1 - \text{IoU} \cdot s$ 가 되는데, 2단계 검출은 정의상 $s < 0.25$ 이므로 비용이 항상 0.75를 초과한다. 그런데 2단계의 임계값은 0.5로 고정되어 있어 어떤 쌍도 매칭될 수 없다. 이 문제는 상류 저장소에서 2026년 7월에 독립적으로 발견되어 수정되었다.

본 연구는 이 문제의 영향을 직접 측정하였다. 2단계에서만 fuse_score를 비활성화하여 이 한 줄만 참조 구현과 맞춘 결과(상류 수정의 다른 변경은 반영하지 않았다), 2단계 매칭이 0건에서 782건으로 살아났고 기준선 HOTA가 -0.324 변화하였다. 이는 이후 제시할 추적 수준 결과($-0.21 \sim -8.90$)보다 한 자릿수 작은 크기이므로 결론을 뒤집지 않으나, 본 연구의 기준선을 문헌의 ByteTrack과 동일시킬 수 없다는 점은 한계로 명시한다.

3.4 검출 불확실성의 산출

두 가지 추정 방식을 비교한다.

NMS 후보 분산 NMS 과정에서 특정 박스에 의해 억제된 후보들의 중심 좌표 공분산을 사용한다. UTrack의 방식과 동일하다. 구현 시 두 가지 함정이 있다. 첫째, NMS 함수는 입력 텐서를 in-place로 변환하므로 호출 이전에 복사해야 한다. 둘째, letterbox 좌표와 원본 좌표가 다르며 좌표 변환이 NMS 이후에 적용되므로, 배율을 NMS 내부에서 측정하면 항상 정확히 1.0이 산출된다. 본 연구는 이 두 함정을 각각 겪었으며 그로 인한 잘못된 결론을 철회한 바 있다. 한편 억제된 후보가 부족하면 공분산이 퇴화하는데, 5.1절과 5.2절의 검출 수준 분석은 이런 검출 5.8%를 제외하고 계산하였다. 반면 추적 수준 실험은 제외 없이 그 값을 그대로 비용에 넣는다. 즉 두 층위의 표본이 정확히 같지 않으며, 이는 추적 수준 음의 결과에 대한 대안 설명으로 배제되지 않는다(7.3절 한계 (7)).

DFL 분포 분산 YOLOv8 계열의 검출 헤드는 박스의 각 변까지의 거리를 16개 구간의 분포로 예측하고 그 기댓값만 사용한다. 본 연구는 버려지는 분산을 불확실성으로 사용한다. 추가 추론 비용이 없다는 장점이 있다. 다만 이 방식은 DFL을 사용하는 검출기 계열에만 적용 가능하다.

3.5 탐색적 분석: σ 의 스케일 특성

모델에 적용하기 전에 σ 가 실제 위치 오차와 어떤 관계인지 확인하였다. 검출된 박스 중심과 대응하는 정답 박스 중심의 오차를 ϵ 이라 할 때, $z^2 = \epsilon^\top \Sigma_d^{-1} \epsilon$ 은 Σ_d 가 올바른 공분산이라면 자유도 2의 카이제곱 분포를 따라야 한다.

이 절의 측정은 NMS 후보 분산에 대한 것이다. 측정 결과 z^2 의 중앙값은 카이제곱 분포의 이론값 대비 **562배**였다(본 연구가 실험에 사용한 UTrack 가중치 기준). 즉 σ 가 실제 오차 대비 크게 과소 추정되어 있다. 이 배율은 검출기가 정한다. 같은 σ 정의로도 COCO 사전학습 가중치에서는 80배로, 7배 차이가 난다. 더 중요한 것은 이 배율이 시퀀스마다도 크게 다르다는 점이다(62 ~ 1840배, UTrack 가중치 기준). 즉 단일 상수를 곱하는 방식의 보정으로는 충분하지 않으며, 보정은 σ 의 보편 함수가 아니라 검출기마다 다시 맞춰야 하는 양이다.

분포의 형태 또한 가우시안과 거리가 있다. 99% 분위수를 50% 분위수로 나눈 비율이 가우시안이라면 약 1.0이어야 하나 실측값은 **12에서 213**이었다. 이는 오차 분포의 꼬리가 매우 두껍다는 뜻이다. 5.2절에서 이 두 관찰(스케일과 꼬리)을 각각 고칠 수 있는지 확인한다.

Chapter 4

방법론

4.1 설계 제약: 덧셈은 할당에 영향을 주지 않는다

검출 불확실성을 비용에 반영하는 가장 단순한 방법은 검출별 스칼라를 더하는 것이다. 그러나 이 형태는 원리적으로 작동하지 않는다.

비용 행렬을 $C = [c_{ij}]$ (i 는 트랙, j 는 검출)라 하고, 검출별 스칼라 u_j 를 더한 행렬을 $C' = [c_{ij} + u_j]$ 라 하자. 모든 실행 가능한 할당이 각 검출을 최대 한 번씩 사용하고, 검출 수가 트랙 수 이하($N \leq M$)라면 모든 검출이 정확히 한 번씩 할당되므로 임의의 할당 π 에 대해

$$\sum_j c'_{\pi(j)j} = \sum_j c_{\pi(j)j} + \sum_j u_j \quad (4.1)$$

가 성립한다. 식 (4.1) 우변의 두 번째 항은 π 에 의존하지 않는 상수이므로 최적 할당은 변하지 않는다.

Proposition 4.1 (검출별 스칼라의 가산 무효성). $N \leq M$ 인 할당 문제에서, 검출에만 의존하는 항을 비용에 더하는 것은 최적 할당을 변화시키지 않는다.

이는 헝가리안 알고리즘의 축소 단계가 근거하는 표준적 성질이며 새로운 정리가 아니다. 다만 본 연구가 강조하는 것은 이 성질의 설계적 함의이다.

따라서 불확실성은 트랙과 상호작용하는 형태로 들어가야 한다. 곱셈 형태 $c_{ij} \cdot u_j$ 는 c_{ij} 가 쌍에 의존하므로 이 제약을 피한다. 2.3절에서 관찰한 바와 같이 문헌은 예외 없이 곱셈을 사용해 왔으며, 본 관찰은 그 선택에 대한 설명을 제공한다.

덧셈을 쓰는 문헌이 반례가 아닌 이유 비용에 항을 더하는 방법이 없는 것은 아니다. OC-SORT(Cao et al., 2023)의 OCM은 방향 일관성 항을 비용에 더한다. 그러나 이 항은 트랙의 진행 방향과 검출의 위치에 함께 의존하는 쌍 항이므로 검출별 스칼라가 아니고, 따라서 식 (4.1)의 조건에 해당하지 않는다. 위 명제가 배제하는 것은 검출에만 의존하는 항이며, 쌍에 의존하는 항은 덧셈으로도 할당에 도달한다.

단, 임계값 경로는 예외이다. 실제 추적기는 헝가리안 해를 구한 뒤 비용이 임계값을 넘는 쌍을 제거한다. 이 단계에서는 상수항도 채택 여부를 바꿀 수 있다. 즉 할당에는 영향이 없으면서 결과는 바뀔 수 있으며, 이 경우 성능 변화를 “정보가 전달되었다”는 근거로 사용해서는 안 된다. 5.5절에서 이를 실측으로 확인한다.

4.2 비교 조건

σ 를 네 가지 경로에 주입하고 각각을 기준선과 비교한다. 경로마다 사용 가능한 σ 추정 방식이 달라 아래와 같이 나뉜다(표 5.3).

- 칼만 필터 측정잡음(NMS 후보 분산): 트랙 상태 갱신 시 R 을 검출별 σ 로 대체. UTrack의 방식을 재현하므로 그들이 쓴 추정 방식을 따랐다.
- 거리 함수(DFL 분포 분산): IoU를 2-Wasserstein 거리로 대체. 트랙과 검출을 각각 가우시안으로 보고 $W^2 = \|\epsilon\|^2 + \text{tr}(\Sigma_t + \Sigma_d - 2(\Sigma_t^{1/2}\Sigma_d\Sigma_t^{1/2})^{1/2})$ 를 계산한다. 이 형태는 위치 항이 박스 크기로 정규화되지 않아 큰 객체가 불리해지므로, 쌍마다 $s_x = \sqrt{w_t w_d}$, $s_y = \sqrt{h_t h_d}$ 로 좌표를 나눈 크기 정규화 변형을 주 조건으로 삼았다. 이는 두 가우시안에 같은 아핀 사상을 적용한 것이므로 여전히 2-Wasserstein이다. 다만 이 선택이 DFL 추정 방식에서는 이득이 아니었다. 정규화하지 않은 조건은 -7.96 으로 주 조건(-8.90)보다 오히려 낮다. 정규화가 도움이 된 것은 박스 크기 조건이다($-7.36 \rightarrow -4.98$). 두 조건 모두 정규화 판본을 주 조건으로 삼은 것은 자료를 보기 전에 정한 것이며, 결과를 보고 고르지 않았다.
- 게이팅(박스 확장): σ 에 비례하여 박스를 확장한 뒤 IoU 계산.
- 매칭 임계값: 장면별로 임계값을 조정. σ 를 포함한 장면 관측량으로 예측.

공정 비교를 위한 통제 거리 함수를 교체하면 비용의 분포 자체가 달라지므로, 임계값을 그대로 두면 채택률이 변한다. 이 경우 성능 차이가 “거리 함수의 차이”인지 “채택률의 차이”인지 구별할 수 없다. 따라서 각 조건의 스케일 상수를 기준선과 채택률이 일치하도록 이분 탐색으로 조정하였다.

게이팅 경로에서는 별도의 대조군을 두었다. σ 로 확장한 조건과 동일한 총 확장량을 박스 크기에 비례하여 분배한 조건을 비교하면, 성능 차이를 “확장 자체의 효과”가 아니라 “확장량을 무엇으로 정했는가”로 귀속할 수 있다. 거리 함수 경로에도 같은 성격의 대조군을 두었다. 동일한 Wasserstein 거리에서 Σ 만 검출기 σ 에서 박스 크기 σ_C 로 바꾼 조건이다. 두 경로 모두 “ σ 를 썼는가”와 “무엇을 σ 로 삼았는가”를 분리한다.

4.3 연관 오라클 여지

음의 결과가 나왔을 때 “적용 경로가 부적절했다”와 “애초에 개선할 여지가 없었다”는 서로 다른 설명이다. 이를 구별하기 위해 본 연구는 연관 오라클 여지를 측정하는 방법을 도입한다.

검출 결과를 고정한 상태에서 1단계 연관의 비용을 다음과 같이 대체한다.

$$c_{ij} = \begin{cases} 0, & \text{트랙 } i \text{와 검출 } j \text{의 정답 ID가 같은 경우} \\ 10^6, & \text{그 외} \end{cases} \quad (4.2)$$

검출에는 정답 박스와 IoU 0.5 이상으로 대응되는 ID를 부여하고, 트랙은 생성 시점의 검출로부터 ID를 물려받는다. 검출, 트랙 관리, 2단계 및 3단계 연관은 모두 그대로 유지한다.

$$\text{개선 여지} = \text{HOTA}(\text{오라클 연관}) - \text{HOTA}(\text{기준선}) \quad (4.3)$$

정답을 사용하므로 이는 성능 주장이 아니라 데이터에 대한 측정이며, 따라서 표본 크기에 따른 검정력 문제가 발생하지 않는다.

이 값은 하한이다 이 값을 “어떤 방법이든 얻을 수 있는 최대치”로 읽어서는 안 된다. 오라클은 정답 ID가 없는 검출(오탐)과 정답 ID가 없는 트랙을 구조적으로 매칭하지 못하므로, 출력에서 오탐 행이 강제로 빠진다. 실제 방법은 그보다 더 많은 오탐을 억제할 수도 있고, 반대로 오라클이 버린 행 중 유용한 것을 살릴 수도 있다. 또한 2~3단계 연관과 트랙 관리는 그대로 두었다.

따라서 이 값은 “연관을 완벽하게 하면 최소한 이만큼은 얻는다”는 하한으로만 읽어야 한다. 본 연구가 이 값을 쓰는 방식 — “개선할 것이 없었다”는 설명을 기각하는 것 — 에는 하한이면 충분하다. 반대로 “여지가 작으니 포기하라”는 판단에는 상한이 필요하며, 이 도구는 그 용도로는 쓸 수 없다.

두 가지 “한”을 구분한다 이 값에는 서로 다른 두 뜻이 겹쳐 있어 혼동하기 쉽다. (가) 1단계 연관만 완벽하게 했을 때 얻는 값의 상한이자, (나) 연관 전반을 개선했을 때 얻을 수 있는 값의 하한이다. 오탐 검출과 미검출은 그대로 두었고 2~3단계 연관과 트랙 관리도 손대지 않았으므로 (나)의 뜻에서 보수적이다. 본 연구는 (나)의 뜻으로만 사용한다. “개선할 것이 없었다”를 기각하는 데는 하한이면 충분하기 때문이다. 이하 이 값을 여지라고만 부르고 “상한”이라는 말은 쓰지 않는다.

4.4 연관 오류에 대한 σ 의 예측력 측정

오라클을 통해 어떤 연관 결정이 틀렸는지 알 수 있으므로, 적용 경로와 무관하게 다음을 직접 물을 수 있다. σ 가 연관 오류를 예측하는가?

1단계 연관에서 실제로 채택된 (트랙, 검출) 쌍마다 다음과 같이 분류한다.

- 정답: 트랙과 검출의 정답 ID가 일치
- 오류(수정 가능): ID가 불일치하지만 올바른 검출이 그 단계에 존재
- 오류(수정 불가): ID가 불일치하고 올바른 검출이 없음(미검출)
- 판별 불가: 검출에 대응하는 정답이 없음(오탐)

이 중 수정 가능한 오류만이 연관 방법이 다룰 수 있는 대상이다. 평가지표로는 σ 가 이 오류를 구별하는 AUC를 사용한다. 분석 단위가 쌍이고 표본이 수만 건이므로 표본 크기 문제가 없다.

4.5 평가지표

추적 성능은 HOTA(Luiten et al., 2021)로 평가한다. HOTA는 검출 정확도(DetA)와 연관 정확도(AssA)의 기하평균으로 정의되어 두 측면을 분리해 볼 수 있다는 장점이 있다. 본 연구는 연관을 다루므로 AssA의 변화를 함께 보고한다.

가중과 비가중을 함께 본다 표준 평가 도구는 여러 시퀀스를 합칠 때 검출 수로 가중하므로 큰 시퀀스가 결과를 지배한다. 본 연구의 데이터에서 MOT17-04 한 시퀀스가 전체 검출의 45%를 차지한다. 가중 여부로 결론의 부호가 뒤집히는 일이 이 연구 과정에서 실제로 두 번 있었다. 따라서 주 관정은 가중 값 하나로 고정하되, 가능한 곳에서는 비가중 시퀀스 평균을 함께 적는다.

평가 코드의 구성 시퀀스가 조용히 누락되는 문제를 방지하기 위해, 표준 평가 도구의 지표 클래스만 사용하고 데이터 적재는 직접 구현하였다. 이는 과거 실험에서 설정 파일의 헤더 누락으로 첫 시퀀스가 평가에서 빠져 결과가 -0.43 에서 -0.62 로 달라진 사례를 겪었기 때문이다. 다만 MOTChallenge의 전처리 절차(distractor 클래스에 매칭된 예측 제거 등)는 원본을 그대로 복제하였다.

통계적 판단 기준 추적 수준 결과의 분석 단위는 장면이며 본 연구는 7개를 사용한다. 이 표본 크기에서 부호검정이 유의수준 0.05를 만족하는 유일한 경우는 7개 전부가 같은 방향인 경우이다($p = 0.0156$). 이 p 값은 7개 장면이 서로 독립이라는 가정 위에서 있다. MOT17의 각 시퀀스는 서로 다른 촬영 장면이므로 이 가정은 합당하나, 0.0156이 이 설계에서 얻을 수 있는 이론적 하한이라는 점은 유의해야 한다 — 즉 만장일치를 얻어도 그 이상 강한 증거는 나올 수 없다. 검출 수준 결과는 분석 단위가 검출이므로 표본이 수만 건이며 이러한 제약이 없다. 5장은 이 두 층위를 명시적으로 구분한다.

Chapter 5

실험 및 결과

5.1 검출 수준: σ 는 위치 오차를 예측한다

먼저 σ 가 위치 오차와 관계가 있는지 확인하였다. 박스 높이가 오차와 σ 양쪽에 영향을 주므로 높이를 통제된 편상관계수를 사용하였다. 결과는 그림 5.1(a)와 같다.




그림 5.1: 동일한 σ , 동일한 시퀀스, 서로 다른 평가 대상. (a) 위치 오차에 대해서는 NMS 후보 분산이 7개 시퀀스 전부, DFL 분포 분산이 6개에서 양의 상관을 보인다. (b) 연관 오류에 대해서는 두 추정 방식이 같린다. DFL은 7개 전부가 무작위 수준(0.5) 아래인 반면 NMS는 4개가 위이고 MOT17-04는 0.897이다. 합친 AUC는 각각 0.4571, 0.5355로 쌍의 독립을 가정하면 둘 다 사전 등록된 기준 0.55 아래이나, 시퀀스 군집을 반영하면 NMS는 판정선을 넘는다(5.7절). 이 산포의 원인은 규명하지 못하였다(6.4절).

NMS 후보 분산의 편상관계수 중앙값은 +0.322이며 범위는 +0.235 ~ +0.453으로 7개 시퀀스 전부에서 양의 값을 보였다. DFL 분포 분산은 중앙값 +0.151로 더 약하고 7개 중 6개에서만 양의 값이었다(MOT17-11에서 -0.029). 이 관계는 검출기를 바꾸어도 유지되었고(COCO 사전학습 가중치 +0.322, MOT 학습 가중치 +0.315), 입력 해상도를 네 단계로 바꾸어도 유지되었다(+0.308 ~ +0.359). 두 수치 모두 NMS 후보 분산에 대한 것이다.

즉 σ 에는 신호가 있다. 어느 검출의 위치가 부정확한지에 대한 정보를 담고 있다.

5.2 검출 수준: NMS 후보 분산은 박스 크기를 대체하지 못한다

다음으로 σ 를 확률 모형으로 사용할 수 있는지 확인하였다. 검출별 공분산을 사용하는 모형(A)과 박스 크기에 비례하는 공분산을 사용하는 모형(C)을 같은 조건에서 비교하였다. 두 모형은 자유 매개변수의 개수가 동일하다(스케일 k 와 자유도 ν).

공정성을 위해 두 모형에 동일하게 Student- t 분포족을 부여하였다. 모형 A에만 두꺼운 꼬리를 허용하면 꼬리의 유연성 덕분에 이기는 것이 당연하므로, 이는 실험의 타당성에 필수적인 통제이다. 결과는 표 5.1과 같다.

표 5.1: 검출별 공분산 모형(A) 대 박스 크기 모형(C)의 held-out 음의 로그우도 비교. 값이 낮을수록 좋으며, 차이가 양수이면 C의 승리이다.

추정 방식	절차	C 승리	쌍별 차이 중앙값	양측 p
NMS 후보 분산	LOSO (7-fold)	7/7	+0.560 nats	0.0156
	전역 적합	7/7	+0.543 nats	0.0156
DFL 분포 분산	LOSO (7-fold)	1/7	-0.096 nats	0.125
	전역 적합	1/7	-0.144 nats	0.125

NMS 후보 분산은 7개 시퀀스 전부에서 박스 크기 모형에 패배하였다. 이는 leave-one-sequence-out(LOSO) 방식과 전역 적합 방식 두 절차에서 동일하게 관찰되었다.

두 절차를 모두 사용한 이유는 LOSO의 각 fold가 학습 데이터를 공유하여 서로 독립이 아니기 때문이다. 7개 fold가 각각 6개 시퀀스로 적합되므로 이웃 fold는 학습 데이터를 5개 공유하며, 7/7을 1/128로 계산하는 것은 반보수적(anti-conservative)이다. 전역 적합은 두 모형의 매개변수 개수가 같다는 점을 이용해 각각 전체 데이터로 한 번씩 적합한 뒤 시퀀스별로 평가하므로 과적합 비대칭 없이 fold 의존성을 제거한다. 두 절차가 같은 결과를 주었으므로 이 우려는 해소된다.

DFL 분포 분산은 방향이 반대이다 같은 절차에서 DFL 분포 분산은 오히려 박스 크기 모형을 7개 중 6개에서 이겼다(LOSO -0.096 nats, 전역 적합 -0.144 nats). 다만 이 결과는 유의성에 도달하지 못하며(양측 $p = 0.125$) 효과 크기도 작다. 4.5절에서 기술한 바와 같이 $n=7$ 에서 유의해지는 유일한 경우는 만장일치이므로 6/7은 원리적으로 유의해질 수 없다. 따라서 이를 **양성 결과로 주장하지 않는다**. 그러나 방향이 두 절차에서 일관된다는 점은 기록해 둔다 — 이는 두 추정 방식의 성격이 정반대임을 시사한다. NMS 후보 분산은 순위는 잘 매기지만(5.1절, +0.322) 모형으로 쓸 수 없고, DFL 분포 분산은 순위가 약한 대신(+0.151) 모형으로는 낫다. 따라서 이 절의 부정적 결론은 NMS 후보 분산에 대한 것이며, 검출기 산출 불확실성 일반에 대한 것이 아니다.

두 모형을 합치면 어떻게 되는가 지금까지의 비교는 σ -만 쓴 모형과 높이-만 쓴 모형의 경주였다. 그런데 5.1절은 σ 가 높이를 통제하고도 위치 오차를 예측한다고 하였으므로

(+0.322), 둘을 함께 쓴 모형이 양쪽을 모두 이겨야 한다는 예측이 따라 나온다. 그 모형을 적합하여 확인하였다.

$$\Sigma_D = k \cdot h^2 \cdot \left(\frac{s}{\text{median}(s)} \right)^g, \quad s = \sqrt{\text{tr}(\Sigma_d)/2} \quad (5.1)$$

여기서 g 는 σ 의 기여를 정하는 지수이고 $g = 0$ 이면 모형 C와 정확히 같다. 중앙값은 훈련 자료에서만 잡아 누출을 막았고, g 는 격자 $[-1, \dots, 2]$ 에서 골랐다. 모수가 C보다 하나 많으므로 held-out에서 이기지 못하면 그것만으로 결론이다.

표 5.2: 합친 모형 D 대 박스 크기 모형 C. 값이 음수이면 D의 승리이다. LOSO와 전역 적합 두 절차 모두 같은 결과를 주었다.

추정 방식	D 승	양측 p	적합된 g	차이 중앙값
NMS 후보 분산	7/7	0.0156	+0.50 (7 fold 전부)	-0.012 nats
DFL 분포 분산	5/7	0.4531	-1.00 (격자 하한)	-0.024 nats

NMS 후보 분산에서는 합친 모형이 7개 시퀀스 전부에서 이긴다($p = 0.0156$). 적합된 g 가 7개 fold 전부에서 +0.50으로 같으므로 적합이 σ 를 실제로 사용한 것이며, 부호도 이론이 예측하는 방향이다. DFL 분포 분산은 5/7로 유의성에 미달하고 적합된 g 가 격자 하한(-1.00)에 붙었다. σ 가 클수록 공분산을 작게 잡는 쪽이 낫다는 뜻이고, 이는 이론과 반대이며 경계에 붙었으므로 잡음이나 교란을 맞추고 있을 가능성이 크다.

그러나 폭이 작다 이 결과를 앞의 결과와 나란히 놓아야 뜻이 산다.

비교	폭
C가 A를 이긴 폭(표 5.1)	+0.560 nats
D가 C를 이긴 폭(표 5.2)	-0.012 nats

47배 차이가 난다. 따라서 정확한 서술은 “ σ 는 확률 모형으로 쓸 수 없다”가 아니라 “ σ 는 박스 크기를 대체할 수 없고, 크기 위에 아주 조금 추가된다”이다. 추가되는 기여분은 통계적으로 유의하지만($p = 0.0156$) 실용적 함의는 거의 없다.

꼬리가 원인이 아니다 모형 A의 적합된 자유도는 7개 fold 전부에서 격자의 하한값($\nu = 1$, 코시 분포)에 도달하였다. 이는 적합 과정이 코시보다 더 두꺼운 꼬리를 원했다는 뜻이며, 즉 최대한의 유연성을 부여했음에도 패배하였다. 3.5절에서 관찰한 두꺼운 꼬리(비율 12~213)는 사실이지만, 그것을 수용하는 분포족을 주어도 결론이 바뀌지 않는다.

스케일 보정도 답이 아니다 컨포멀 예측을 이용해 스케일을 보정하면 held-out 커버리지가 10.5%에서 96.1%로 개선되어 목표치 95%에 도달하였다. 즉 스케일은 고칠 수 있다. 그럼에도 박스 크기 모형과의 우열은 바뀌지 않았다. 문제가 스케일이 아니라는 뜻이다.

5.3 추적 수준: 네 경로 모두 음의 결과

σ 를 세 가지 경로에 직접 주입하고, 네 번째로 σ 를 포함한 장면 관측량으로 매칭 임계값을 조정하여 HOTA를 측정한 결과는 표 5.3와 같다. 네 값을 같은 무게로 세어서는 안 된다 — 표의 별표가 표시하듯 본 연구의 최소 검출 가능 효과(3.31 HOTA, 6.5절)를 넘는 것은 둘뿐이고, 나머지 둘은 부호가 음수일 뿐 0과 구별되지 않는다. 이 절이 말할 수 있는 것은 “넷이 모두 졌다”가 아니라 “어느 경로도 이득 쪽으로 해상도를 넘지 못했다”이다.

표 5.3: 적용 경로별 결과. 모든 조건에서 검출은 비트 단위로 동일하다. 경로마다 사용한 σ 추정 방식이 다르므로 함께 적는다. 별표를 붙인 두 값만 본 연구의 최소 검출 가능 효과(3.31 HOTA, 6.5절)를 넘는다. 나머지 둘은 0과 구별되지 않으므로 “음의 결과 넷”을 같은 무게로 세어서는 안 된다. † 게이팅의 대조군은 무엇을 맞추는가에 따라 격차의 부호가 갈린다(표 B.1).

적용 경로	σ 추정 방식	비교 대상	Δ HOTA	통제
칼만 필터 R	NMS 후보 분산	기준선	-0.62	저자 코드 재현
거리 함수	DFL 분포 분산	기준선	-8.90*	채택률 일치, 검출 동일
게이팅(박스 확장)	NMS 후보 분산	기준선	-4.33*	확장량 일치 대조군 별도†
매칭 임계값	장면 관측량	기본값	-0.21	LOSO 예측 규칙
같은 경로를 박스 크기 σ_C 로 바꾸면				
거리 함수	박스 크기	기준선	-4.98	위와 동일

거리 함수 경로에서도 같은 대조가 성립한다 2-Wasserstein 거리에 검출기 σ (DFL 분포 분산)를 넣으면 -8.90 인데, 같은 거리 함수를 박스 크기 σ_C 로 바꾸면 -4.98이다. 즉 검출기 σ 가 박스 크기보다 3.93 HOTA 열등하다(표 5.3의 반올림된 값으로 빼면 3.92가 되나, 본문 값은 반올림 전 HOTA 52.10과 56.02에서 계산한 것이다). 게이팅 경로에서 관측된 격차(3.81)와 크기가 비슷하지만 두 값을 재현으로 읽어서는 안 된다 — 게이팅 쪽 격차는 무엇을 맞추었는가에 따라 -8.5에서 +0.2까지 움직이므로(표 B.1) 그 하나의 값과 3.93을 나란히 놓는 것 자체가 우연에 기댄다. 두 실험이 사용한 추정 방식이 다르고(게이팅은 NMS 후보 분산, 거리 함수는 DFL 분포 분산), 본 연구의 시퀀스 간 표준편차(중앙값 2.60)에 비하면 0.12의 일치는 구별할 수 없는 크기이다. 채택률을 기준선과 일치시켰으므로 이 차이는 채택률 변화로 설명되지 않는다.

집계 방식에 의존하는가 표의 값은 검출 수 가중이다(4.5절). 시퀀스별 값이 남아 있는 거리 함수 경로에 대해 비가중 평균을 함께 계산하였다. 검출기 σ 조건은 -11.68(가중 -8.90), 박스 크기 조건은 -5.96(가중 -4.98)이다. 부호가 같고 비가중 쪽이 오히려 더 나쁘므로, 이 결과는 집계 방식에 의존하지 않으며 가중 집계가 본 연구에 유리한 쪽이었다. 시퀀스별로는 7개 중 6개에서 기준선보다 나뉘었다(양측 부호검정 $p = 0.125$, 4.5절의 기준으로 유의성 미달).

5.4 격자와 게이팅 대조군: 우열은 무엇을 맞추었는가에 달려 있다

5.3절의 두 대조는 각각 다른 추정 방식을 사용하였으므로 그것만으로는 원인을 가를 수 없다. 이 절은 격자를 채워 경로와 추정 방식을 분리하려 시도하고, 그 시도가 게이팅 경로에서 어디까지 성립하는지를 밝힌다.

경로와 추정 방식을 함께 가른다 앞 절의 두 대조만으로는 음의 결과를 “경로가 나쁘다”와 “그 경로에 쓴 추정 방식이 나쁘다”로 나눌 수 없다. 이를 분리하기 위해 두 경로와 세 추정 방식을 하나의 재생 파이프라인 안에서 모두 실행하였다. 검출 캐시, 추적기 설정, 평가 절차가 전부 동일하며, 거리 함수는 채택률을 기준선(0.9633)에 맞추고 게이팅은 총 확장 면적을 서로 맞추었다(모두 목표의 100.0%). 게이팅의 확장은 검출과 트랙 양쪽에 준다 — 검출에만 주면 트랙 박스가 커진 검출 안으로 들어가 교집합은 그대로인데 합집합만 커지므로, 이미 잘 맞는 쌍의 IoU가 오히려 떨어져 확장이 채택을 넓히는 것이 아니라 좁히는 개입이 된다(7.4절).

표 5.4: 추정 방식 $\times$ 적용 경로 격자. 기준선(HOTA 61.002) 대비 Δ HOTA이며, 괄호는 기준선보다 나빠진 시퀀스 수이다. $\dagger$ NMS 후보 분산 $\times$ 게이팅은 개입이 성립하지 않는다. 이 조건에서는 확장량을 키울수록 1단계 채택률이 오히려 떨어져(7.4절) 확장이 채택을 넓히는 개입이 되지 못한다. 값을 적되 판정에서 제외한다. 이 표의 값은 이 실험 안에서만 비교한다. 5.3절 앞부분의 -8.90 , -4.98 , -4.33 은 다른 파이프라인에서 나온 값이므로 같은 줄에 놓지 않는다.

추정 방식	거리 함수	게이팅
NMS 후보 분산	-10.568 (6/7)	$-8.470^\dagger$ (7/7)
DFL 분포 분산	-8.573 (6/7)	-1.960 (6/7)
박스 크기 σ_C	-4.922 (6/7)	$+0.074$ (2/7)

여섯 칸 가운데 다섯이 유효하며, 그중 넷이 음수이다(그림 5.2). NMS 후보 분산 $\times$ 게이팅은 확장이 채택을 넓히는 방향으로 작동하지 않아 측정이 성립하지 않는다. 따라서 이 조합에 대해서는 추정 방식과 경로 중 무엇이 원인인지 말할 수 없다. 이는 “넣어 보았더니 졌다”와 다른 종류의 사실이며, 두 가지를 동일하게 취급하지 않기 위해 판정에서 제외한다.

남은 한 칸인 박스 크기 $\times$ 게이팅은 $+0.074$ 로 양수이다. 다만 이 값은 본 연구의 최소 검출 가능 효과(3.31 HOTA, 6.5절)의 $1/45$ 이고 시퀀스별 부호도 $5/7$ ($p = 0.453$)이므로 이득의 증거가 아니라 “박스를 키우는 것 자체는 사실상 공짜”로 읽어야 한다. 실험 3이 다른 파이프라인에서 같은 결론에 이르렀다(-0.52) — 두 값이 일치한다는 뜻이 아니라, 둘 다 0과 구별되지 않는다는 뜻이다.

따라서 교란은 해소되지 않는다. 사전 등록된 판정 규칙은 유효한 다섯 칸이 모두 음수일 것을 요구하였고 한 칸이 양수이므로, **한계 (1)을 결과로 승격하지 않는다**. 말할



그림 5.2: 추정 방식 $\times$ 적용 경로 격자(표 5.4을 그림으로 옮긴 것). 막대는 검출 수 가중 $\Delta HOTA$, 눈금은 비가중 시퀀스 평균이며 여섯 칸 전부 부호가 같다(4.5절). 회색 띠는 본 연구의 최소 검출 가능 효과 ± 3.31 (6.5절)이고 그 안의 값은 0과 구별되지 않는다. 유일한 양수 칸인 박스 크기 $\times$ 게이팅(+0.074)이 여기에 든다. 파선으로 그린 칸은 개입이 성립하지 않은 조합이므로 “넣어 보았더니 졌다”로 읽어서는 안 된다. 오른쪽 숫자는 기준선보다 나빠진 시퀀스 수이다.

수 있는 것은 좁다 — 검출기 σ 는 측정이 성립한 세 칸 전부에서 음수이며, 양수인 칸은 검출기 σ 가 아니라 대조군이다.

집계 방식에 의존하지 않는다(4.5절). 비가중 시퀀스 평균으로는 거리 함수 열이 -13.949 , -11.029 , -5.974 , 게이팅 열이 -7.658 , -0.853 , $+0.636$ (각 열에서 NMS, DFL, 박스 크기 순)이며 여섯 칸 전부 가중 값과 부호가 같다.

격자를 가로로 읽으면 박스 크기가 이긴다 각 경로 안에서 검출기 σ 와 대조군을 뺀다.

경로	NMS - 크기	DFL - 크기
거리 함수	-5.646	-3.651
게이팅	(개입 불성립)	-2.034

측정이 성립한 세 조합 전부에서 박스 크기가 검출기 σ 를 이긴다. 거리 함수에서 5.6, 3.7 HOTA, 게이팅에서 2.0 HOTA이다. 단 게이팅의 값은 총 확장 면적을 맞춘 결과이며, 맞춤 기준을 바꾸면 부호까지 뒤집힌다(표 B.1) — 거리 함수의 두 조합과 달리 게이팅에서의 우열은 조건부로만 말할 수 있다. 다만 추정 방식과 경로 중 어느 쪽 효과가 큰지는 이 자료로 말할 수 없다. 추정 방식 간 최대 차이는 5.646(거리 함수), 경로 간 최대 차이는 6.613(DFL 분포 분산)이며 둘의 격차 0.97은 본 연구의 최소 검출 가능 효과(3.31)의 1/3에 불과하다. 두 값을 나란히 적되 우열은 주장하지 않는다.

이 문단은 앞선 판을 철회하고 다시 쓴 것이다. 이전 측정은 확장을 검출에만 주었고, 그 판에서는 게이팅의 세 칸이 $-6.8 \sim -9.6$ HOTA로 함께 눌러 NMS 후보 분산과 박스 크기의 차이가 $+0.121$ 로 사라져 보였다. 확장을 양쪽에 주도록 고치자 그 단서가 사라졌다. 잘못된 통제가 값의 수준을 낮추었을 뿐 아니라 추정 방식 간 차이를 압축하여 실제로는 없는 경로 의존성을 만들어 낸 것이다(추정 방식 간 폭 $2.8 \rightarrow 8.5$).

게이팅의 우열은 맞춤 기준에 달려 있다. 박스를 키우는 것 자체는 거의 비용이 들지 않으나(-0.52), 확장량을 σ 가 결정하도록 하면 기준선 대비 -4.33 이 된다. 그러나 그 격차를 하나의 비율로 귀속할 수는 없다 — 세 가지 맞춤 기준으로 다시 측정하면 값이 -8.543 에서 $+0.191$ 까지, 범위 8.735 HOTA로 움직여 최소 검출 가능 효과(3.31)의 두 배가 넘고 부호까지 갈린다(부록 B). 더구나 다른 경로가 쓰는 주 기준 — 채택률 일치 — 는 NMS 후보 분산에 대조군 자체가 존재하지 않는다. 하나의 비율로 귀속하던 이전 판의 서술은 이 때문에 철회하였다.

이것은 UncertaintyTrack에 대한 반증이 아니다. 두 결과는 부호가 반대이지만(본 연구 -4.33 , 그들 mMOTA $+2.2$) 구조가 달라 직접 비교할 수 없다. 그들은 확장한 박스를 2차 통과에서 GIoU로 사용하는 반면 본 연구는 1단계 IoU에 직접 적용하였다. 그들이 보고한 mMOTA $+2.2$ 에 대해 말하려면 같은 구조로 다시 측정해야 한다. 본 결과가 뒷받침하는 것은 확장량을 무엇으로 정하는가를 통제하지 않으면 확장의 이득을 불확실성에 귀속할 수 없다는 방법론적 주장이며, 그들의 수치가 틀렸다는 주장이 아니다.

한 가지 관측을 덧붙인다. 세 가지 Wasserstein 변형 모두에서 MOT17-13 한 시퀀스만 이득이었다($+6.47$, $+3.20$, $+5.87$). 이 시퀀스는 개선 여지가 가장 크고($+12.17$) 카메라 움직임도 가장 크다(6.3 절). 다만 한 장면의 관측이고 세 변형은 같은 기제를 공유하므로 독립적인 증거가 아니다. 연결 관계는 확인하지 못하였다.

각 경로에 실제로 둔 통제와 남은 취약점은 부록 A에 정리하였다. 검출 캐시는 모든 조건에서 비트 단위로 동일하고, 거리 함수는 채택률을, 게이팅은 총 확장량을 기준선에 맞추었다. 남은 한계는 추정 방식이 경로마다 다르다는 점이며(표 5.3), 그 결과 각 음의 결과는 “그 경로가 나쁘다”와 “그 경로에 쓴 추정 방식이 나쁘다”를 구별하지 못한다(7.3절 한계 (1)).

5.5 추적 수준: 덧셈과 곱셈의 실측 비교

4.1절의 설계 제약을 실제 데이터에서 확인하였다. 매 연관 호출마다 기준선 비용, 검출별 스칼라를 더한 비용, 곱한 비용 세 가지를 나란히 풀어 비교하였다. 두 섭동의 평균 크기는 동일하게 맞추었다(평균 $|\Delta\text{cost}| = 0.1998$). 결과는 표 5.5과 같다.

표 5.5: 검출별 스칼라의 가산과 곱셈 비교. 1단계 연관 호출 2,645건 기준. 두 섭동의 평균 크기를 $|\Delta\text{cost}| = 0.1998$ 로 동일하게 맞추었다. 맞추지 않으면 비교가 성립하지 않는다.

항목	덧셈	곱셈
임계값 적용 전 할당 일치율 ($N \leq M$, 2,614건)	99.54%	96.06%
불일치 12건 중 최적성 위배	0건	—
임계값 적용 전 할당 일치율 ($N > M$, 31건)	54.84%	—
임계값 적용 후 채택 쌍이 달라진 호출	65.41%	32.85%
ΔHOTA (기준선 61.002 대비)	-3.750	-1.014

덧셈 조건에서 할당이 달라진 12건은 전부 동점이었다. 즉 기준선 비용 기준으로 두

할당의 총비용이 동일하며, 헝가리안 알고리즘이 동점 상황에서 어느 최적해를 반환할지 정하지 않기 때문에 발생한 차이이다. 최적성이 위배된 사례는 0건이다. 명제가 실제 데이터에서 성립한다. 명제의 조건이 필요하다는 것도 확인된다. $N > M$ 인 31건에서는 일치율이 54.84%로 떨어진다.

동시에 4.1절이 예고한 예외도 확인되었다. 할당은 사실상 변하지 않는데 임계값 단계에서 65.41%의 호출에서 채택 결과가 달라지고, 최종 HOTA는 -3.750 이 된다. 즉 기여는 0인데 해롭기만 하다. 반면 곱셈은 할당의 96.06%만 유지되어(전체 호출 기준 95.88%) 실제로 할당에 도달하며, 성능 저하도 -1.014 로 더 작다.

5.6 추적 수준: 개선 여지는 존재하는가

네 경로가 모두 실패한 이유로 “애초에 개선할 여지가 없었다”는 설명이 가능하다. 이를 확인하기 위해 4.3절의 연관 오라클 여지를 측정하였다. 결과는 표 5.6과 같다.

표 5.6: 연관 오라클 여지이다. 검출을 고정하고 1단계 연관만 정답으로 해결한 결과이다. 아래 두 행은 $+3.122$ 를 알파별로 귀속한 것이다. AssA 만 바꾼 값이 $+2.352$ 이고 나머지가 잔차이므로 교체 순서에 의존한다(본문 참조).

조건	HOTA	DetA	AssA	IDSW
기준선 (IoU)	61.002	58.801	64.036	275
연관 오라클	64.124	60.034	69.113	211
개선 여지	$+3.122$	$+1.233$	$+5.077$	-64
연관 정확도의 기여분	$+2.352$	—	—	—
출력에서 오답이 빠진 기여분	$+0.770$	—	—	—

개선 여지는 $+3.122$ HOTA로 존재한다(검출 수 가중). 비가중 시퀀스 평균으로는 $+5.372$ 로 더 크다 — 여지가 작은 MOT17-04가 가중 집계에서 큰 비중을 차지하기 때문이다. 두 값의 부호가 같으므로 이 결론은 가중 방식에 의존하지 않는다. 본 연구가 시도한 네 경로는 모두 음의 값이었으므로, “애초에 개선할 것이 없었다”는 설명은 기각된다. 4.3절에서 언급한 대로 이 값은 오답과 미검출을 수정하지 않으므로 보수적이다. 그림 5.3에 이 여지와 본 연구가 시도한 경로들을 나란히 두었다.

DetA가 함께 오르는 이유, 그리고 그 크기 검출 캐시가 동일함에도 DetA가 $+1.233$ 변화한다. 오라클 연관은 정답 ID가 다른 검출과의 매칭을 거부하므로 출력되는 트랙 행이 12.4% 감소하고, 제거된 것의 상당수가 오답이기 때문이다. HOTA의 DetA는 검출 자체가 아니라 추적기 출력의 검출 품질이며, 그 출력을 무엇으로 채울지는 연관이 결정한다.

그렇다면 $+3.122$ 중 얼마가 연관 정확도의 기여분인가? HOTA는 각 임계값 α 에서 $\sqrt{\text{DetA}_\alpha \cdot \text{AssA}_\alpha}$ 로 정의되고 이를 α 에 대해 평균한다. 따라서 성분을 갈아 끼워 기여를 귀속할 수 있다 — DetA는 기준선 값을 두고 AssA만 오라클 값으로 바꾸면 63.354, 즉 $+2.352$ (전체의 75.3%)를 연관 정확도에 귀속할 수 있고 나머지 $+0.770$ 이 출력에서 오답




그림 5.3: 왼쪽: 시퀀스별 기준선 HOTA와 오라클까지의 여지. 여지가 장면에 따라 13배 갈린다. 오른쪽: 전체 합산 기준 $\Delta HOTA$. 오라클 둘과 카메라 움직임 보상만 0보다 크다(다만 앞의 둘은 달성치가 아니라 오라클 값이고, 카메라 보상의 +0.430은 7.2점의 기준으로는 지지되는 이득이 아니다. 시퀀스별로 3개 양수, 2개 음수이다). 검출기 σ 를 주입한 네 경로는 전부 0보다 작다. 거리 함수는 추정 방식을 갈라 둘로 그렸다. 열은 막대가 박스 크기 σ_C (-4.98), 진한 막대가 검출기 σ (-8.90)이다. 비교 조건은 표 5.3와 같다.

이 빠진 기여분이다. 다만 이는 교체 순서에 의존하는 귀속이다. 반대로 DetA만 오라클 값으로 바꾸면 잔차가 달라지므로, 75.3%는 분해의 유일한 답이 아니라 한 가지 귀속 방식의 결과이다.

이는 +3.122가 과대평가라는 뜻이 아니다. 완벽한 연관기를 넣으면 실제로 +3.122를 얻으며, 출력에서 오탐이 빠지는 것도 연관이 좋아진 결과이다. 다만 “연관 정확도만으로 3.1점”로 읽히지 않도록 구성을 밝힌다. 더 보수적인 +2.352를 기준으로 삼아도 본 연구의 네 경로(-0.21 ~ -8.90)는 모두 그 아래이므로 결론은 바뀌지 않는다.

여지는 장면에 몰려 있다 시퀀스별 개선 여지는 +0.91(MOT17-04)에서 +12.17(MOT17-13)까지 13배 이상 차이가 난다. 이는 6.3절에서 별도로 분석한다.

5.7 추적 수준: σ 는 그 여지에 도달할 수 있는가

개선 여지가 존재한다면, 다음 질문은 σ 로 그 여지에 도달할 수 있는가이다. 4.4절의 방법으로 직접 측정하였다. 채택된 쌍의 구성은 표 5.7, 예측력 측정 결과는 표 5.8와 같다.

연관 방법이 다룰 수 있는 오류는 전체의 3.89%이다. 이 비율과 5.6절의 +3.122 HOTA를 직접 대응시키지는 않는다. 단위가 다르고, 쌍 하나가 HOTA에 기여하는 크기는 트랙 길이와 장면에 따라 달라지기 때문이다.

두 추정 방식 모두 사전 등록된 기준 0.55에 미치지 못한다. 그러나 양상은 전혀 다르다.

표 5.7: 1단계에서 채택된 연관 쌍의 구성 (총 47,194쌍)

분류	건수	비율
정답	27,734	58.77%
오류 (수정 가능)	1,837	3.89%
오류 (수정 불가, 미검출)	1,952	4.14%
판별 불가 (오답)	15,671	33.21%

표 5.8: σ 가 수정 가능한 연관 오류를 예측하는가 (정답 27,734건 대 오류 1,837건). 사전 등록한 판정 기준은 AUC 0.55이며, 판정은 첫 행(합친 AUC)으로만 한다. 아래 행들은 진단이다. 시퀀스별 중앙값 0.6275가 0.55를 넘지만 이것으로 판정하지 않는다.

지표	NMS 후보 분산	DFL 분포 분산
AUC ($\sigma \rightarrow$ 수정 가능한 오류)	0.5355	0.4571
시퀀스 안 순위 정규화 후 (탐색)	0.5480	0.4134
시퀀스별 중앙값	0.6275	0.4115
시퀀스별 0.5 초과	4/7	0/7
박스 높이를 통제된 편상관계수	+0.0328	-0.0220
AUC (박스 크기 기반 σ_C)	0.4661	
(참고) 위치 오차에 대한 편상관계수	+0.322	+0.151

DFL 분포 분산 — 일관된 음의 결과 AUC 0.4571로 무작위 수준보다 오히려 미세하게 낮고, 시퀀스별로 보아도 0.330 ~ 0.485로 **7개 전부**가 0.5 아래이다(그림 5.1(b)). 시퀀스 안에서 순위 정규화한 뒤 합쳐도 0.4134로 변하지 않는다. 위치 오차에 대한 편상관계수 +0.151과 나란히 놓으면 검출 품질에 대한 약한 신호조차 연관으로는 전혀 옮겨가지 않는다는 것이 분명하다.

NMS 후보 분산 — 기준 미달이나 일관성이 낮다 합친 AUC는 0.5355로 기준 0.55 아래이지만 방향이 반대이고, 시퀀스별로는 0.409 ~ 0.897로 **4개**가 0.5 위이다. 특히 MOT17-04는 0.897에 달한다. 시퀀스 안 순위 정규화 후에도 0.5480으로 거의 변하지 않으므로, 이 불일치는 시퀀스 간 σ 스케일 차이로 설명되지 않는다 (6.4절). 또한 이 추정 방식에서는 σ 가 박스 크기 기반 σ_C (0.4661)를 이긴다. 5.2절 및 DFL과 반대 방향이다.

판정선까지의 여유 사전 등록한 기준은 AUC < 0.55 이고 관측값이 0.5355이므로 **여유가 크지 않다**. 점추정만 보고할 것이 아니라 구간을 함께 보아야 한다. DeLong의 구조적 분산으로 계산한 95% 신뢰구간은 다음과 같다(난수 시드를 고정한 부트스트랩 400회로 교차 확인하였고 두 경로가 일치하였다).

신호	AUC	쌍 독립 95% CI	시퀀스 군집 95% CI	> 0.55
NMS 후보 분산	0.5355	[0.5215, 0.5495]	[0.4516, 0.6936]	4/7
DFL 분포 분산	0.4571	[0.4427, 0.4716]	[0.3672, 0.5840]	0/7
박스 크기 σ_C	0.4661	[0.4489, 0.4833]	[0.3481, 0.6691]	2/7

그러나 이 구간들은 쌍의 독립을 가정한다. 29,571개의 쌍은 7개 장면에 군집되어 있고, 한 트랙이 여러 프레임 동안 잘못 연관되면 거의 같은 쌍이 반복해서 생긴다. 시퀀스를 복원추출하는 군집 부트스트랩($B = 2000$)으로 다시 내면 구간이 9배 넓어진다(NMS의 표준오차 $0.0071 \rightarrow 0.0628$, 설계 효과 77.6 배). NMS의 상한은 0.6936으로 판정선을 넘고, 시퀀스별로도 7개 중 4개가 0.55를 초과한다(범위 0.409 ~ 0.897). 따라서 NMS에 대해서는 사전 등록된 판정이 서지 않는다. 반면 DFL은 시퀀스별로 7개 모두 판정선 아래이므로(0.330 ~ 0.485) 그 음의 결과는 군집을 반영해도 유지된다.

이 재분석은 사전 등록된 것이다. 자료를 보기 전에 군집 단위를 시퀀스로, 재표집 횟수를 2000으로, 그리고 주 판독을 구간이 아니라 시퀀스별 부호 개수로 고정하였다. 군집이 7개뿐이면 부트스트랩 구간 자체가 낙관적이기 때문이며, 이는 6.5절의 기준을 검출 수준에 그대로 적용한 것이다.

측정 방식을 바꾸면 — 행 안에서 다시 측정하기 위 AUC에는 구조적 한계가 있다. AUC는 채택된 쌍을 독립적으로 늘어놓은 주변부 판별력인데, 헝가리안이 실제로 푸는 문제는 한 트랙의 행 안에서 후보들의 상대 순서이기 때문이다. 행 안에서 정답과 오답을 가르는 능력이 있어도 전역 순위에서는 묻힐 수 있고, 그 반대도 가능하다.

“수정 가능한 오류”는 정의상 올바른 검출이 같은 호출에 존재했던 경우이므로 짝지어 비교할 수 있다. 오류 1,837건 각각에 대해 실제로 채택된 오답 검출과 그때 존재했던 정답 검출의 신호를 비교하였다(정답 후보가 여럿이면 트랙 예측 박스와 IoU가 가장 큰 것을 사용하며, 이는 자료를 보기 전에 정하였다).

표 5.9: 행 안 짝 비교. 각 수정 가능한 오류에서 정답 검출의 신호가 오답 검출보다 작은 비율이다. 0.5보다 크면 그 신호가 행 안에서 정답 쪽을 가리킨다는 뜻이다. 비교 대상 1,837쌍, 동물 0건. 군집 CI는 시퀀스를 복원추출한 부트스트랩($B = 2000$)이며, 마지막 열은 7개 시퀀스 가운데 0.5를 넘는 개수다.

신호	정답을 고른 비율	쌍 독립 CI	시퀀스 군집 CI	> 0.5
DFL 분포 분산	0.4415	0.419 ~ 0.464	0.366 ~ 0.504	2/7
NMS 후보 분산	0.4720	0.449 ~ 0.495	0.427 ~ 0.510	1/7
박스 크기 σ_C	0.6451	0.623 ~ 0.667	0.482 ~ 0.813	4/7

두 결과가 나온다. 첫째, 검출기 산출 σ 는 측정 방식을 바꾸어도 정답을 고르지 못한다. 두 추정 방식 모두 점추정이 0.5보다 낮고, 시퀀스별로도 0.5를 넘는 것이 각각 1개와 2개뿐이다. 군집을 반영한 구간은 0.5를 아슬하게 포함하지만(0.427 ~ 0.510, 0.366 ~ 0.504) 어느 방향으로든 신호가 있다는 근거는 아니다. 따라서 “주변부 지표라서 놓친 것”이라는 반론은 이 자료에서는 지지되지 않는다. 둘째, 박스 크기는 행 안에서 정답을 64.5%로 고른다. 주변부 AUC(0.4661)만 보면 박스 크기도 예측력이 없어 보이지만, 헝가리안이 실제로 묻는 질문으로 바꾸면 강한 신호가 드러난다.

두 값은 우연 수준의 반대쪽에 놓인다 이 대비를 “묻혔던 신호가 드러났다”로만 읽으면 한 가지를 놓친다(그림 5.4).




그림 5.4: 같은 신호를 두 방식으로 측정한 것(표 5.8와 표 5.9을 겹쳤다). (a) 세로축은 오답 쪽 검출의 신호가 더 클 확률이며 두 방식에 공통이다. 박스 크기만 0.5를 가로지른다. 비교 대상이 “자료 어디에 있는 정답 쌍”에서 “같은 호출의 정답 검출”로 바뀌기 때문이다. 주변부 값은 교차하는 두 분포의 요약이므로 방향으로 읽어서는 안 된다(5.7절). 검출기 σ 둘은 어느 방식으로 측정해도 0.5 아래이다. (b) 행 안 정답률을 시퀀스별로 본 것. 빈 원이 7개 시퀀스, 가로선이 점추정, 열은 막대가 시퀀스 군집 95% 구간이다. 열 위의 숫자는 0.5를 넘은 시퀀스 수이며, 박스 크기의 4/7과 0.5를 포함하는 구간이 이 관측을 탐색적인 것으로 만든다(6.5절).

σ_C 의 두 값 — 주변부 0.4661(표 5.8)과 행 안 0.6451(표 5.9) — 은 같은 형태의 확률이다. 오답 쪽 검출의 신호가 더 클 확률이며, 비교 대상만 “자료 어디에 있는 정답 쌍”에서 “같은 호출의 정답 검출”로 바뀌었는데 하나는 우연 수준 아래, 다른 하나는 위이다.

다만 주변부 값을 방향으로 읽어서는 안 된다. 부록 C는 0.4661을 “박스가 작을수록 연관이 틀리기 쉽다”로 읽었으나, 분포를 보면 그렇게 요약되지 않는다. 수정 가능한 오류 쪽 σ_C 는 아래쪽에 더 몰려 있지만(하위 사분위 37.4 대 70.6 px) 중앙값은 오히려 높고(89.8 대 86.8) 위쪽 꼬리는 얇다(90분위 200.1 대 222.0). 두 분포가 교차하므로 0.4661은 이동이 아니라 교차를 요약한 순위 통계이며, 하나의 방향으로 옮겨 적을 수 없다. 반면 행 안 값은 방향이 일정하다. 잘못 채택된 검출이 같은 호출의 정답 검출보다 큰 경우가 64.5%이다. 즉 주변부 측정은 순위가 낮을 뿐 아니라 쓸 만한 규칙 자체를 정의하지 못한다.

이는 모순이 아니라 두 측정 방식이 다른 질문을 묻기 때문이다. 주변부 비교는 서로 다른 장면과 프레임의 쌍을 가로질러 세우고, 행 안 비교는 한 결정 안으로 범위를 좁혀 장면 간 성분을 구성상 제거한다. 두 값의 차이와 위의 교차는 측정이다. 그러나 교차의 원인은 측정하지 않았다. 장면 구성이 순위를 지배한 결과라는 설명이 자연스러우나 본 연구는 그것을 분리하지 않았다.

아래는 해석이며 본 연구가 시험하지 않았다. 검출별 스칼라를 비용 전체에 넣는 형태는 두 방향을 한 행렬 안에 섞으므로 서로를 상쇄시킬 수 있다. 이는 박스 크기가 이 점검을 0.6451로 통과하고도 시험한 두 경로 어느 쪽에서도 기준선을 넘지 못한 것(거리 함수 -4.92 , 게이팅 $+0.07$, 표 5.4)에 대한 설명 후보이다. 4.1절의 명제가 여기에 그대로

붙는다. 행 안의 상대 순서로만 작동하는 양은 검출별 스칼라가 아니라 쌍에 의존하는 항으로 들어가야 할당에 도달한다. 이 형태를 실제로 넣어 재는 것은 7.4절에 남긴다.

이 두 번째 결과가 본 연구의 여러 관측을 한꺼번에 설명한다. 왜 5.3절의 대조군(박스 크기)이 거리 함수에서 검출기 σ 를 이겼는지(게이팅에서는 맞춤 기준에 따라 갈린다, 표 B.1), 그리고 표 2.1에서 검출기 산출 σ 를 쓴 쪽이 일관되게 지는 것과도 정합한다. 다만 성공 조건을 기하학적 정보로 좁힐 근거는 없다(6.2절). 반대로 주변부 AUC를 선별 도구로 쓰면 박스 크기 계열을 잘못 기각하게 된다 — 7.2절의 절차를 행 조건부로 정의하는 이유이다.

선행 연구의 반대 주장 본 절의 결과는 기존에 보고된 관찰과 방향이 다르다. Wang 등 (Wang et al., 2020)은 3차원 데이터 연관에서 올바른 연관의 평균 신뢰도가 0.80, 잘못된 연관이 0.39로 크게 갈린다고 보고하였고, UncertaintyTrack(Lee and Waslander, 2024)은 정성적으로 “연관 실패로 이어지는 검출은 올바르게 연관된 검출에 비해 위치 불확실성이 상대적으로 높은 경향”을 관찰하였다. 본 연구의 측정은 그 정도의 분리를 재현하지 않는다. 다만 세 가지가 다르므로 직접적인 반박으로 읽어서는 안 된다 — (가) 그들은 신뢰도 또는 정성적 관찰이고 본 연구는 AUC이며, (나) 영역이 3차원 라이다 대 2차원 영상으로 다르고, (다) 본 연구는 오탐 쌍을 제외하였는데 그 모집단에서는 약한 신호가 관찰되었다(표 6.3). 같은 조건에서 재현하는 것이 남는 과제이다.

주장의 범위 사전 등록된 판정 기준으로는 두 추정 방식 모두 “연관 오류에 대한 정보가 없다”이다. 그러나 NMS의 시퀀스별 산출을 보면 “전혀 없다”는 단언은 자료가 지지하지 않는다. 본 연구가 주장하는 것은 다음으로 좁힌다.

σ 가 연관 오류에 대해 갖는 예측력은 위치 오차에 대한 것보다 훨씬 약하고, 추정 방식과 장면에 따라 불안정하다. 쌍의 독립을 가정한 구간에서는 어느 경우에도 사전 등록된 활용 기준에 도달하지 못하며, 시퀀스 군집을 반영하면 NMS에 대해서는 그 판정 자체가 서지 않는다.

이는 네 경로가 모두 음의 결과를 보인 것과 일관된다. 안정적으로 전달할 신호가 없으면 어떤 주입 형태를 쓰더라도 이득이 나지 않는다.

박스 크기 기반 신호도 다르지 않다 σ_C 의 AUC는 0.4661로 역시 기준에 미치지 못한다. 즉 연관 오류를 식별하지 못하는 것은 특정 추정 방식만의 문제가 아니라 검출 품질 신호 전반에 나타나는 현상이다. 다만 NMS 추정 방식에서는 σ 가 σ_C 를 이겼으므로, “검출 쪽 정보로는 접근할 수 없다”고까지 단정하지는 않는다.

Chapter 6

분석: 왜 도달하지 못하는가

6.1 네 경로의 음의 결과에 대한 재해석

5장의 결과를 종합하면 다음과 같은 해석이 가능하다.

본 연구는 처음에 “ σ 는 위치 오차의 순위를 알려주므로, 그 순위를 연관에 전달하면 도움이 될 것”이라는 가정 위에서 네 경로를 비교하였다. 그런데 5.7절의 측정값은 그 가정이 성립하지 않거나, 성립하더라도 매우 약하고 불안정함을 보인다. 위치 오차의 순위와 연관 오류의 순위는 같은 것이 아니다. 이에 따라 설명이 표 6.1과 같이 바뀐다.

표 6.1: 음의 결과에 대한 설명의 변화

기존 설명	5.7절 이후의 설명
적용 경로가 부적절하다	전달할 신호가 거의 없거나 불안정하다
스케일이 80~562배 어긋나서	스케일을 제거해도(순위 정규화) 바뀌지 않는다
가우시안 가정이 맞지 않아서	분포족을 바꾸어도 결론이 같다(5.2절)

이 해석은 서론에서 인용한 UncertaintyTrack 저자들의 추측에 대한 답이 된다. **다변량 가우시안이 참 분포를 잘 나타내지 못한다는 지적은 옳다** — 본 연구는 꼬리 비율을 12~213으로 측정하였다. 그러나 그것이 원인은 아니다. 자유도를 제약 없이 적합한 Student- t 를 부여해도 7개 시퀀스 전부에서 결론이 동일하다. 다만 이 답변은 NMS 후보 분산에 근거한다. UncertaintyTrack은 검출기가 학습으로 산출한 공분산을 사용하므로 추정 방식이 다르며, DFL 분포 분산에서는 방향이 반대였다는 점(5.2절)을 함께 고려해야 한다.

6.2 같은 경로, 다른 추정 방식: 문헌의 성패에 대한 설명

2.3절에서 관찰한 바와 같이 칼만 필터 측정잡음이라는 같은 경로에서도 문헌의 결과가 갈린다. 표 2.1의 해당 행만 추리면 다음과 같다 — 박스 크기를 넣은 UCMCTrack(Yi et al., 2024)은 SOTA를 달성하였고, 검출 신뢰도를 넣은 NSA Kalman(Du et al., 2023)은 널리 채택되었으며, 검출기가 산출한 σ 를 넣은 두 연구(UTrack(Solano-Carrillo et al., 2024), UncertaintyTrack(Lee and Waslander, 2024))는 모두 손실을 보고하였다.

즉 성공한 쪽의 공통점은 “박스 크기”가 아니라, 실패한 쪽의 공통점이 “검출기가 산출한 σ ”이다. 이 구분이 중요하다. LG-Track은 위치 품질을, DeepSORT와 Bae는 트랙 쪽 이력을 사용하여 이득을 보고하므로 성공 조건을 기하학적 정보로 좁힐 근거는 없다. 다만

NSA Kalman을 반례로 쓸 수는 없다 — 논문은 R_k 를 “preset constant”로 서술하지만, 이 연구가 사용한 구현(및 StrongSORT 계열 전반)에서 R_k 는 박스 크기에 비례하고 NSA는 거기에 $(1-c)$ 를 곱할 뿐이다. 이는 2.3절이 fuse_score에 대해 지적인 것과 같은 종류의 간극이다. 논문의 서술과 구현이 다르다. 자료가 지지하는 것은 검출기 산출 불확실성을 넣은 쪽이 일관되게 진다는 관찰뿐이다.

5.2절의 결과가 이 패턴에 대한 설명을 제공한다. NMS 후보 분산은 밀도 모형으로 박스 크기 모형에 7개 시퀀스 전부에서 패배하였다. **다만 이 설명은 NMS 후보 분산에 한정된다.** DFL 분포 분산은 같은 비교에서 방향이 반대였으므로(5.2절), “검출기 산출 σ 는 모형으로 쓸 수 없다”는 일반 명제로 확장하지는 않는다. 문헌의 두 실패 사례가 사용한 추정 방식은 NMS 후보 분산(UTrack)과 학습된 공분산(UncertaintyTrack)이며, 후자는 본 연구가 재현하지 않았다(7.4절).

이 관찰은 본 연구의 비교 기준인 모형 C의 정당성도 뒷받침한다. C는 임의로 세운 기준선이 아니라 실제로 배포된 방법의 모형이다. 다만 정확히는 같은 계열의 다른 형태이다. NWD는 $\text{diag}(w^2/4, h^2/4)$ 의 비등방 형태에 고정 스케일을, UCMCTrack은 $(\sigma_m w, \sigma_m h)$ 의 비등방 형태를 사용하는 반면 본 연구의 C는 $\text{diag}(h^2, h^2)$ 의 등방 형태에 스케일을 적합한다.

등방 형태가 불리한 선택인가 그렇지 않다. 비등방 형태 $\text{diag}(w^2, h^2)$ 는 중심 오차의 분산비 $\text{Var}(e_x)/\text{Var}(e_y)$ 가 $(w/h)^2$ 와 같다고 가정하는데, MOT17 보행자에서 이 값은 0.128이다. 실측한 분산비는 0.973(MAD 기준, 합친 15,453건)으로 등방에 가깝고, 7개 시퀀스 중 비등방 가정에 부합하는 것은 **하나도 없었다**(범위 0.291 ~ 3.898). 표본분산으로 계산하면 0.337로 낮아지지만 이 역시 0.128의 2.6배이다. 두 추정량이 크게 갈리는 것은 오차 꼬리가 두껍기 때문이며(3.5절의 꼬리 비율 12~213), 어느 쪽을 쓰든 비등방 가정은 지지되지 않는다. 따라서 등방 형태는 배포된 모형을 약화시킨 변형이 아니다.

다만 이것은 공분산의 모양에 대한 측정이지 적합도 비교가 아니다. 비등방 C를 실제로 적합해 NLL을 비교하려면 검출 박스의 폭이 필요한데 본 연구의 캐시에는 높이만 저장되어 있다. 7.4절에 후속 과제로 남긴다.

6.3 개선 여지는 어디에 있는가: MOT17-13 분석

5.6절에서 개선 여지가 시퀀스별로 +0.91에서 +12.17까지 갈리는 것을 확인하였다. 가장 큰 MOT17-13을 분석하였다.

정답 쌍이 임계값 밖에 있다 ByteTrack은 IoU가 0.2 미만인 쌍의 매칭을 거부한다. 따라서 동일한 정답 ID를 가진 연속 프레임의 박스 쌍이 IoU 0.2 미만이라면, **그 쌍은 IoU 기반 방법으로는 원리적으로 찾을 수 없다.** 측정 결과 MOT17-13에서는 이런 쌍이 5.43%였으며, 나머지 6개 시퀀스에서는 전부 0%였다.

원인은 카메라 움직임으로 보였으나 반증되었다 MOT17-13의 프레임 간 이동량은 박스 높이 대비 0.107로 나머지(0.013)의 8.2배이며, 이 중 78%가 전역 성분(카메라)이다. 따라서 카메라 움직임 보상으로 회복될 것으로 예상하고 검증하였다. 결과는 표 6.2와 같다.

표 6.2: 카메라 움직임 보상의 회복률. 오라클 보상은 정답 궤적으로 측정한 전역 이동, 실제 보상은 영상에서 추정한 값을 사용하였다.

시퀀스	개선 여지	오라클 보상	회복률	실제 보상	추정 이동(px)
MOT17-02	2.02	+0.00	0%	-0.08	0.18
MOT17-04	0.91	+0.00	0%	+0.00	0.19
MOT17-05	4.86	-0.36	-7%	+0.40	5.03
MOT17-09	2.75	-0.48	-18%	-0.00	0.29
MOT17-10	6.02	+1.58	26%	+1.57	3.33
MOT17-11	8.87	+3.79	43%	+3.96	4.67
MOT17-13	12.17	-0.16	-1%	-1.66	14.75

카메라 움직임이 가장 큰 시퀀스에서 보상이 작동하지 않았다. 정지 카메라 시퀀스(MOT17-02, 04)에서 변화가 정확히 0이었으므로 개입 자체는 정확하게 이루어졌다. 따라서 MOT17-13의 개선 여지는 평행이동으로 설명되지 않으며, 회전이나 스케일 변화 또는 불규칙한 움직임일 가능성이 남는다. 시퀀스가 하나뿐이므로 이를 구별할 수 없어 미해결로 남긴다.

한편 카메라 움직임 보상 자체는 다른 시퀀스에서 작동하였다(전체 +0.430, MOT17-11에서 여지의 43%). 영상에서 추정한 값이 정답 기반 값과 사실상 동일하였으므로(+0.430대 +0.430) 추정 정확도는 병목이 아니다.

6.4 NMS 후보 분산의 장면 간 산포 — 설명하지 못하였다

5.7절에서 NMS 후보 분산의 AUC가 시퀀스별로 0.409 ~ 0.897로 크게 갈렸다. DFL에서는 이런 일이 없었다(0.330 ~ 0.485). 원인을 찾으려 시도하였으나 규명하지 못하였다. 시도한 것과 그 결과를 그대로 적는다.

유일하게 시험한 가설 — 시퀀스 간 σ 스케일 차이가 순위를 지배한다. 은 기각되었다. 시퀀스 안에서 순위 정규화한 뒤 합쳐도 AUC가 0.5355 → 0.5480으로 거의 변하지 않았고, 되짚어 보니 전제부터 틀렸다(부록 C).

오탐 쌍에 대해서는 다르다 위 분석은 채택 쌍의 62.7%(29,571 건)만 사용하였다. 오탐 쌍 15,671 건(33.2%)과 미검출로 인한 수정 불가 오류 1,952 건(4.1%)을 제외했기 때문이다. 앞의 것은 정답을 판별할 수 없고, 뒤의 것은 연관 방법이 고칠 수 없다. 그런데 5.6절은 여지 +3.122 중 +0.770을 오탐 행이 출력에서 빠진 기여분으로 귀속하였다. 즉 여지의 4분의 1에 대해서는 σ 를 시험하지 않은 셈이며, 오탐 표시야말로 검출 불확실성의 전형적 용도이므로 이를 따로 측정하였다.

표 6.3: 오탐 매칭을 구별하는가(오탐 15,671건 대 정답 27,734건). AUC는 부호 대칭이므로 $|AUC - 0.5|$ 를 함께 적는다. 박스 크기 행의 편상관이 “—”인 것은 통제 변수(높이)와 신호가 같아 정의되지 않기 때문이다.

신호	AUC	$ AUC - 0.5 $	높이 통제 편상관
박스 크기 σ_C	0.3830	0.1170	—
NMS 후보 분산	0.5698	0.0698	+0.0510
DFL 분포 분산	0.4712	0.0288	+0.1589

세 가지가 관찰된다. 첫째, 여기서도 박스 크기가 가장 강하다(0.117 대 0.070, 0.029) — 본 연구 전체의 논지와 같은 방향이다. 둘째, NMS 후보 분산은 오탐을 약하게 식별한다(0.070). 셋째, DFL 분포 분산은 원시 AUC와 편상관의 부호가 반대이다(0.4712 대 +0.1589) — 박스 크기가 두 변수를 함께 몰기 때문이며, 크기를 통제하면 “ σ 가 클수록 오탐”으로 뒤집힌다.

따라서 본 절의 결론은 오탐 모집단으로 확장되지 않는다. 수정 가능한 오류에 대해서는 두 추정 방식 모두 사전 등록 기준에 미달하지만, 오탐에 대해서는 약한 신호가 있다. 이는 본 연구가 시험한 네 경로가 모두 매칭 비용을 다루었고 검출 억제는 다루지 않았다는 사실과 맞물린다. 7.3절 한계 (2)에 적는다.

본 연구가 적는 방식 설명을 찾지 못했으므로 **설명하지 않는다**. 사전 등록한 판정 기준(합친 $AUC < 0.55$)은 두 추정 방식 모두 충족하므로 본 연구의 결론은 유지되지만, NMS 추정 방식의 결과는 DFL만큼 깨끗하지 않다는 점을 결론에 반영하였다(7.1절 다섯째). 이 산포를 가르려면 장면 수를 늘려야 한다.

6.5 표본 크기에 대한 분석

본 연구의 추적 수준 결과는 7개 장면에 기반한다. 이 표본 크기가 무엇을 말할 수 있는지 계산하였다.

시퀀스 간 HOTA 차이의 표준편차는 조건에 따라 0.42 ~ 5.78(중앙값 2.60)이었다. 이 변동성의 중앙값에서 검정력 80%로 검출 가능한 최소 효과는 3.31 HOTA이다(표 6.4). 그러나 조건마다 시퀀스 간 변동성이 다르므로, 중앙값에서 나온 하나의 기준으로 모든 조건을 재는 것은 옳지 않다. 각 대조를 자기 자신의 SD로 다시 재면 결과가 달라진다. 본 연구가 내린 여섯 개의 판정이 모두 자기 해상도를 넘지 못한다. 가장 큰 효과인 거리 함수조차 관측 -5.96(비가중)에 대해 검출 가능한 최소 효과가 7.09이다.

이는 측정이 틀렸다는 뜻이 아니다. 이 7개 장면에서의 측정은 정확하다. 재생이 결정적이고 검출은 조건 간 비트 단위로 같다. 한계는 그 측정을 새로운 장면으로 일반화하는데 있다. 따라서 본 연구의 추적 수준 서술은 모두 “이 7개 장면에서 이러하였다”로 읽어야 하며, “ σ 를 넣으면 성능이 떨어진다”는 일반 명제로 읽어서는 안 된다.

데이터셋을 추가해도 부족하다. MOT17(7), MOT20(4), DanceTrack 검증 분할(25), KITTI(21)를 모두 합해도 약 57개이다(DanceTrack의 분할은 원문으로 확인하였고 KITTI

표 6.4: 표본 크기 계산. 시퀀스 간 표준편차 중앙값 2.60, 검정력 80%, 유의수준 0.05 기준. 마지막 행만 “필요”가 아니라 “가용”한 수이다.

질문	필요 장면 수
0.3 HOTA 차이를 검출 (t 검정)	591
0.3 HOTA 차이를 검출 (부호검정)	933
“차이 없음”을 주장 (동등성 검정)	646
(참고) 공개 데이터셋 전체를 합해 가용한 장면 수	약 57

의 21은 확인하지 못하였다. 다만 57과 591의 차이가 자릿수이므로 결론은 이 수치에 의존하지 않는다). 따라서 본 연구는 추적 수준 결과를 추론이 아니라 기술로 제시하며, 각 경우에 오라클 여지를 함께 보고한다.

결정 단위로 분해해도 부분적으로만 해결된다 분석 단위를 장면에서 개별 검출로 바꾸면 표본이 GT 검출 53,890건이 된다. 이 단위에서 시퀀스 간 차이의 분산을 측정 오차와 실제 이질성으로 분해한 결과, 블록 부트스트랩의 블록 길이를 25에서 100까지 바꾸어도 측정 오차의 비중이 0.36을 넘지 않았다. 즉 **실제 이질성이 최소 64%**이며, 더 정밀하게 측정해도 시퀀스 간 차이가 줄지 않는다. 다만 시퀀스당 블록이 6~11개뿐이어서 이 분해 자체의 정밀도에도 한계가 있다 — “7개로 충분한가”를 7개로 답할 수 없다.

반면 검출 수준 결과는 이 제약을 받지 않는다. 5.1절, 5.2절, 5.7절의 결론은 분석 단위가 검출 또는 연관 쌍이며 표본이 수만 건이다. 본 연구의 주 주장은 이 층위에 있다.

Chapter 7

결론

7.1 요약

본 연구는 검출 불확실성을 다중객체추적의 데이터 연관에 활용할 수 있는지를 통제된 조건에서 검증하였다. 여섯 결과로 정리된다.

검출 수준 (1) σ 에는 신호가 있다 — 박스 높이를 통제한 편상관계수가 NMS 후보 분산에서 중앙값 +0.322 이고 7개 시퀀스 전부가 양수이다(DFL 분포 분산 +0.151, 6/7). 검출기와 입력 해상도를 바꾸어도 유지된다. (2) 그럼에도 확률 모형으로는 박스 크기에 비례하는 모형에 7개 시퀀스 전부에서 패배한다($p = 0.0156$, LOSO와 전역 적합 두 절차 동일). Student- t 를 자유도 하한까지 적합해도, 컨포멀 보정으로 커버리지를 96.1%까지 올린 뒤에도 같다. 둘을 합친 모형이 크기 모형을 7/7로 이기므로 크기가 설명하지 못하는 부분이 남아 있으나, 그 기여분은 -0.012 nats로 크기가 σ 를 이긴 쪽(+0.560)의 1/47에 불과하다. DFL 분포 분산은 같은 절차에서 방향이 반대였으므로(6/7, 유의성 미달) “검출기 산출 불확실성은 모형으로 못 쓴다”는 일반화는 성립하지 않는다.

추적 수준 — 이 7개 장면에 대한 기술이다 (3) 네 경로 모두 음의 결과였다($-0.21 \sim -8.90$). 다만 넷이 같은 무게는 아니다. 칼만 필터(-0.62)와 매칭 임계값(-0.21)은 최소 검출 가능 효과(3.31)의 1/5과 1/16 이어서 0과 구별되지 않으며, 이득 쪽으로 해상도를 넘은 경로는 없다. 두 경로와 세 추정 방식의 격자에서도 유효한 다섯 칸 가운데 넷이 음수이고 양수인 한 칸은 검출기 σ 가 아니라 대조군이므로(5.4절, 표 5.4), **교란은 해소되지 않았고 본 연구는 이를 결과가 아니라 한계로 유지한다.** (4) 그러나 개선 여지 자체는 존재한다. 1단계 연관만 정답으로 해결하면 +3.122 HOTA를 얻는다(하한이며 “최대치”가 아니다, 4.3절). 따라서 “애초에 개선할 것이 없었다”는 설명은 기각된다. (5) σ 로는 그 여지에도달하기 어렵다. 수정 가능한 연관 오류에 대한 AUC가 DFL 0.4571, NMS 0.5355로 쌍의 독립을 가정하면 둘 다 사전 등록한 기준 0.55 아래이나, 시퀀스 군집을 반영하면 NMS의 상한이 0.6936으로 판정선을 넘고 시퀀스별로도 4/7이 이를 초과하여 **추론이 아니라 관측으로만 적는다.** DFL은 시퀀스별 7/7이 판정선 아래여서 군집을 반영해도 유지된다.

(6) 무엇으로 측정하는가 헝가리안이 실제로 푸는 형태 — 같은 호출 안에서 정답 검출과 오답 검출을 짝지어 비교하는 것 — 로 재면 박스 크기가 정답을 0.6451로 고른다. 채택된 쌍 전체의 주변부 지표로는 0.4661로 무용해 보이던 신호이다. 두 측정값은 같은

형태의 확률인데 우연 수준의 반대쪽에 놓인다. 비교 대상만 다르다(5.7절). 다만 시퀀스 군집을 반영하면 구간이 0.5를 포함하고 7개 중 넘은 것이 4개뿐이므로 탐색적 관측이다.

종합하면 검출기가 산출한 σ 의 순위 정보는 주로 검출 품질에 대한 것이고 연관 판단으로 전이되는 부분은 훨씬 작다. 이는 네 경로의 음의 결과를 “경로 선택의 문제”가 아니라 “전달할 신호 자체가 약하다”로 재해석하게 하며, 문헌에서 검출기 산출 σ 를 쓴 쪽이 일관되게 지는 패턴과도 정합한다(6.2절). 다만 셋을 단서로 남긴다. NMS 후보 분산의 장면 간 산포는 규명하지 못하였고(6.4절), 제외한 오탐 쌍에는 약한 신호가 관찰되며(표 6.3), 박스 크기는 행 안 점검을 통과하고도 시험한 두 경로에서 기준선을 넘지 못하였다(거리 함수 -4.92 , 게이팅 $+0.07$). 따라서 본 연구가 자료로 뒷받침하는 것은 측정 방식의 차이이며 “박스 크기를 쓰면 이득이 난다”가 아니다. 실무적 함의는 7.2절에 따로 적었다.

부수적으로, 검출별 스칼라를 비용에 덧셈으로 넣으면 최적 할당이 변하지 않음을 실제 데이터에서 확인하였다(불일치 12건 전부 동점, 최적성 위배 0건). 동시에 임계값 단계를 통해 65.41%의 호출에서 채택 결과가 달라지고 HOTA가 -3.750 이 된다. 즉 할당에 대한 기여는 0이면서 성능에는 해로울 수 있으며, 이는 문헌이 예외 없이 곱셈 형태를 사용해 온 사실을 설명한다.

7.2 제안: 신호에 투자하기 전에 측정하는 절차

본 연구의 방법은 그대로 사전 점검 절차가 된다. 새로운 신호를 연관에 넣어 보려는 연구자는 주입 형태를 설계하기 전에 다음 두 가지를 측정할 수 있으며, 둘 다 추적기 재생한 번씩이면 된다.

1. 이 벤치마크에 여지가 얼마나 있는가 — 연관 오라클 값을 측정한다(4.3절). 본 연구의 데이터에서는 $+3.122$ HOTA(연관 정확도에 귀속되는 기여분 $+2.352$)였다. 이 값은 하한이므로 “여지가 크다”는 결론에만 쓸 수 있고, “여지가 없으니 포기하라”에는 쓸 수 없다(4.3절). 음의 결과를 해석할 때 “개선할 것이 없었다”를 기각하는 용도가 본래의 쓰임이다.
2. 이 신호가 행 안에서 정답을 고르는가 — 오라클로 오답 쌍을 찾은 뒤, 같은 호출에 있었던 정답 검출과 짝지어 비교한다(5.7절). 분석 단위가 쌍이므로 표본이 수천 건이고 장면 수가 적어도 측정할 수 있다. 반드시 행 조건부로 재야 한다. 본 연구는 처음에 채택된 쌍 전체의 주변부 AUC로 이를 측정하였는데, 그 방식으로는 박스 크기 신호가 0.4661로 무용해 보인다. 행 안에서는 0.6451로 정답을 고른다(다만 시퀀스 군집을 반영하면 탐색적 관측이다. 7.1절 여섯째). 주변부 지표로 선별하였다면 그 계열을 시작 전에 기각했을 것이다. 다만 이 점검은 필요조건이지 충분조건이 아니다. 반례가 본 연구 안에 있다 — 박스 크기는 이 점검을 0.6451로 통과하고도 격자의 두 경로 어느 쪽에서도 기준선을 넘지 못하였다(거리 함수 -4.92 , 게이팅 $+0.07$, 5.4절). 통과는 “넣어 볼 값어치가 있다”를 뜻하지 “이득이 난다”를 뜻하지 않는다.

본 연구가 이 순서를 따랐다면 네 경로를 모두 시도하기 전에 방향을 바꿀 수 있었을 것이다. 실제로는 반대 순서로 진행하였고, 네 경로가 모두 실패한 뒤에야 “전달할 신호가 있는가”를 물었다. 이 논문의 실질적 권고는 그 순서를 뒤집으라는 것이다.

한 가지 덧붙인다. 본 연구에서 전체 합산 기준 양의 값을 낸 유일한 개입은 σ 가 아니라 카메라 움직임 보상이었다(+0.430). 다만 이것을 “이득”이라고 부르려면 본 연구가 σ 에 적용한 것과 같은 기준을 적용해야 한다. 시퀀스별로는 3개가 양수, 2개가 음수, 2개가 0이며(표 6.2) 결합 값은 MOT17-11과 MOT17-10 두 장면이 만든 것이다. 4.5절의 기준($n=7$ 에서는 만장일치만 증거)으로 보면 이는 지지되는 이득이 아니다. 정확한 서술은 “MOT17-11에서 여지의 43%를 회복하였다”이며, 일반적 권고로 확장하지 않는다. 그럼에도 방향은 시사적이다. 여지가 큰 장면의 실패 원인을 먼저 진단하고 그에 맞는 개입을 고르는 접근이, 범용 신호를 여러 경로에 넣어 보는 것보다 이 데이터에서는 나왔다.

7.3 한계

본 연구의 한계를 결론을 위협하는 것과 범위를 한정하는 것으로 나누어 적는다. 앞의 둘은 사실로 밝혀지면 결론이 바뀌고, 뒤의 여섯은 결론은 유지되나 그것이 어디까지 적용되는지를 좁힌다.

결론을 위협하는 것

(1) 격자가 교란을 해소하지 못하였다 5.4절에서 두 경로와 세 추정 방식의 격자를 채웠으나 여섯 칸 가운데 다섯만 유효하고 그중 넷이 음수였다. 사전 등록한 판정 규칙은 유효한 칸이 모두 음수일 것을 요구하였으므로 “경로가 나쁜가 추정 방식이 나쁜가”라는 교란은 해소되지 않았고, 본 연구는 이를 결과로 승격하지 않는다. 두 가지가 남는다. 첫째, NMS 후보 분산 $\times$ 게이팅은 개입이 성립하지 않았다. 확장량을 키울수록 1단계 채택률이 오히려 떨어져 확장이 채택을 넓히는 개입이 되지 못하였다. 둘째, 박스 크기 $\times$ 게이팅이 +0.074로 양수였다. 다만 이 값은 최소 검출 가능 효과의 1/45이고 시퀀스별 부호도 5/7이므로 이득의 증거가 아니라 “박스를 키우는 것 자체는 사실상 공짜”로 읽어야 한다. 그리고 나머지 두 경로(칼만 필터, 매칭 임계값)는 격자에 넣지 않았다. 칼만 필터 경로는 저자 코드의 구조를 따라야 하고, 매칭 임계값 경로는 애초에 검출별 σ 가 아니라 장면 관측량을 사용하므로 같은 격자에 놓기 어렵다. 따라서 “네 경로 모두 음성”이라는 서술의 근거는 두 경로에서는 격자로, 나머지 두 경로에서는 단일 조건으로 되어 있다.

(2) 시험하지 않은 모집단, 그리고 설명하지 못한 산포 성격이 다른 두 위협을 한 번호 아래 묶었다. 앞의 것은 측정하지 않은 부분에 대한 것이고, 뒤의 것은 측정했으나 설명하지 못한 것이다. 첫째, 5.7절의 주 측정은 채택 쌍의 62.7%만 사용하였고, 제외한 오답 쌍에 대해서는 약한 신호가 관찰되었다(표 6.3). 본 연구의 네 경로는 모두 매칭 비용을 다루었으므로 이 신호를 쓸 수 있는 지점 — 검출 억제나 트랙 생성 억제 — 는 시험하지 않았다. 이는 본 연구가 검증하지 못한 가장 큰 부분이다. 다만 거기서도 박스 크기(0.117)

가 검출기 $\sigma(0.070, 0.029)$ 보다 강하므로, 시험하더라도 같은 결론에 이를 수 있다.

둘째, NMS 후보 분산의 시퀀스별 AUC가 0.409 ~ 0.897로 갈렸고(6.4절) 원인을 찾지 못하였다. 유일하게 검정한 가설(시퀀스 간 스케일 차이)은 기각되었다. 장면 수를 늘려 이 산포가 실재하는지 표본 변동인지 가리는 것이 우선 과제이다.

범위를 한정하는 것

(3) **표본 크기** 추적 수준 결과는 7개 장면에 기반하며, 이 표본에서 검출 가능한 최소 효과는 3.31 HOTA이다. 0.3 HOTA 수준의 차이를 통계적으로 검출하려면 591개 장면이 필요하나 공개 데이터셋을 모두 합해도 약 57개이다. 따라서 본 연구는 추적 수준 결과를 기술로 제시하고 오라클 여지를 함께 보고하였다. 주 결론은 표본이 수만 건인 검출 수준에 두었다. 그런데 그 수만 건은 독립이 아니다. 쌓은 7개 장면에 군집되어 있고, 한 트랙이 여러 프레임 동안 잘못 연관되면 거의 같은 쌍이 반복해서 생긴다. 시퀀스 군집 부트스트랩으로 다시 내면 설계 효과가 3배에서 89배까지이고, 그 결과 두 판정의 지위가 내려간다. NMS의 AUC는 판정선을 더 이상 충족하지 못하고(5.7절), 박스 크기의 행 안 우위는 탐색적 관측이 된다. 본 연구의 음의 결과는 이 재분석에서도 유지되지만(DFL의 AUC는 시퀀스별 7/7이 판정선 아래), 유일한 양의 주장이 독립 가정에 기대고 있었다는 사실은 기록해 둔다. 다만 5.2절의 판정은 이 재분석의 대상이 아니다. 그 부호검정의 분석 단위가 쌍이 아니라 시퀀스 7개이므로, 쌍의 군집이 그 p 값에 들어가지 않는다. 군집 단위를 트랙으로 잡으면 더 촘촘하겠으나 트랙 식별자가 조건마다 달라 시퀀스로 고정하였다.

(4) **단일 검출기 계열** 실험에 사용한 검출기는 모두 YOLOv8 계열이다. “검출기와 무관”이라는 주장은 같은 구조의 서로 다른 가중치 두 가지에 근거하므로 제한적이다. 또한 DFL 분포 분산이라는 추정 방식 자체가 이 계열에만 존재한다. 다른 구조(YOLOX, RT-DETR 등)로의 확장이 향후 과제이다.

(5) **기준선 구현 문제** 3.3절에서 기술한 바와 같이 사용한 구현체는 2단계 연관이 작동하지 않는 상태였다. 영향을 측정한 결과 -0.324 로 본 연구의 결과 크기보다 한 자릿수 작으나, 본 연구의 기준선을 문헌의 ByteTrack과 동일시할 수 없다. 수정된 구현에서 나머지 조건을 재실행하는 것이 향후 과제이며, 이 경우 스케일 상수도 다시 결정해야 한다.

(6) **비표준 데이터 분할** `val_half`는 표준 벤치마크 분할이 아니므로 공개된 수치와 직접 비교할 수 없다. 이는 UTrack의 재현 조건을 맞추기 위한 선택이었다.

(7) **두 층위의 표본이 다르다** 3.4절에서 기술한 대로 검출 수준 분석은 퇴화 공분산 5.8%를 제외하고, 추적 수준 실험은 제외하지 않는다. 즉 검출 수준의 신호 측정($+0.322$)은 예측 변수 자체를 기준으로 선택된 부분표본에서 계산되었다. 추적 수준에서 그 5.8%가

$\sigma = 0$ 으로 비용에 들어가는 것이 음의 결과에 얼마나 기여하는지는 측정하지 않았다. 퇴화 검출에 박스 크기 사전분포로 대체값을 넣고 한 경로를 다시 돌리면 확인할 수 있다.

(8) 두 경로의 비가중 값 미측정 4.5절에서 밝힌 대로 가중 여부로 부호가 뒤집힌 전례가 있다. 본 연구가 보고하는 값들의 상태는 다음과 같다. 두 값을 모두 확인하였고 부호가 같은 것: 오라클 여지(5.6절), 2단계 수정(3.3절), 거리 함수 경로(5.3절). 두 값을 확인하였고 부호가 뒤집힌 것: 매칭 임계값 경로(부록 A, -0.207 대 $+0.249$) — 다만 두 값 모두 절댓값이 0.3 미만이라 판정은 같다. 확인하지 못한 것: 칼만 필터 경로와 게이팅 경로는 시퀀스별 출력을 보관하지 않아 비가중 값을 내지 못하였다. 두 효과의 크기가 -0.62 와 -4.33 이므로 뒤집힐 가능성은 낮다고 보지만 이는 측정이 아니라 판단이다.

7.4 향후 과제

위 한계 가운데 (1)의 나머지 두 경로와 (2)는 검출 캐시가 고정되어 있으므로 재생만으로 확인할 수 있다 — 이것이 가장 먼저 할 일이다. 그 밖에 이 연구가 남긴 질문 가운데 셋을 적는다.

행 조건부 형태로 넣어 보기 5.7절은 같은 신호(σ_C)를 두 측정 방식으로 재어 우연 수준의 반대쪽에 놓이는 두 값을 얻었다. 주변부 0.4661은 교차하는 두 분포의 요약이라 방향을 정의하지 못하고, 행 안 0.6451만 일정한 방향을 갖는다. 검출별 스칼라를 비용 전체에 넣는 형태는 이 둘을 한 행렬에 섞으므로, 박스 크기가 행 안 점검을 통과하고도 두 경로에서 지는 것과 무관하지 않을 수 있다. 이는 해석이며 본 연구가 측정하지 않았다. 측정하려면 신호를 행 안의 상대 순서로만 쓰는 형태로 넣어야 한다. 다만 순진한 행 중심화는 퇴화한다. 1단계 비용 행렬은 모든 검출이 모든 트랙의 후보이므로 행 평균을 빼면 그 평균이 행마다 같아 다시 상수가 되고 4.1절의 명제로 되돌아간다. 상대 순서는 그 트랙의 예측 박스와 겹치는 검출들처럼 행마다 달라지는 후보 집합 안에서 매겨야 쌍에 의존하는 항이 된다.

경쟁 신호로 행 안 점검을 대조하기 표 5.9는 박스 크기가 행 안에서 정답을 0.6451로 고른다는 것을 보이지만, “검출 품질을 나타내는 양이면 무엇이든 통과하는가”는 시험하지 않았다. 무작위 신호의 행 안 기댓값은 정의상 0.5이므로 필요한 것은 무작위 대조군이 아니라 경쟁 신호 대조군이다. 가장 비용이 낮은 후보는 검출 신뢰도 s 이며, 이미 검출 캐시에 들어 있으므로 행 안 비교를 한 번 재생하며 열 하나를 더 기록하면 된다. 두 결과가 모두 쓸모 있다 — s 가 0.5 근처라면 박스 크기의 0.6451이 검출 품질 대리변수 일반의 성질이 아니라는 근거가 되고, 반대로 높게 나오면 2.3절이 “선택한 이유를 밝힌 문헌이 없다”고 적은 $\text{cost} = 1 - \text{IoU} \cdot s$ 형태에 대한 측정값이 된다.

게이팅의 공정한 대조군 본 연구는 게이팅에서 σ 조건과 대조군을 세 가지 기준으로 맞추어 보았고 격차의 부호가 같았다(부록 B). 더구나 다른 경로가 쓰는 기준인 채택률

일치는 NMS 후보 분산에 대조군 자체가 존재하지 않는다. 확장의 세기와 채택률이 하나의 매개변수(α)에 묶여 있는 것이 원인이므로 둘을 분리하는 개입을 설계해야 한다. 본 연구는 그것을 하지 않았고, 그 전까지 게이팅 경로의 우열은 기준을 밝혀야만 말할 수 있다.

그 밖에 다음 넷은 저장소에 기록으로 남긴다. (가) MOT17-13의 개선 여지 +12.17이 카메라 움직임 보상으로 회복되지 않는 원인 — 회전과 스케일 변화 중 무엇인지 가르려면 유사한 시퀀스가 더 필요하다(6.3절). (나) 비등방 공분산의 적합도 — 6.2절은 중심 오차의 분산비를 재었을 뿐 비등방 모형을 적합해 NLL을 비교하지는 않았고, 그러려면 검출 박스의 폭을 캐시에 함께 저장해야 한다. (다) 선행 연구의 구조 복제 — 본 연구의 게이팅은 1단계 IoU에, UncertaintyTrack은 2차 통과 GIoU에 적용하므로 그들의 수치를 반박하려면 구조를 그대로 복제해야 한다. (라) 다른 벤치마크의 개선 여지 — 오라클 측정은 재사용 가능한 도구이고, UncertaintyTrack이 이득을 보고한 BDD100K의 여지는 측정하지 않았다.

7.5 재현성

본 연구의 조건 간 비교는 모두 사전 등록된 계획에 따라 수행되었으며, 실험 계획 문서는 데이터 생성 이전에 저장소에 커밋되었다. 저장소에 PREREG 문서 15편이 있고, 초기 실험 몇 편은 계획을 실험 README에 적었다.

사전 등록 없이 수행한 것이 넷 있으므로 밝힌다. 표 6.4의 표본 크기 계산, 6.2절의 중심 오차 분산비(0.973), 6.3절의 MOT17-13 진단, 5.7절의 박스 크기 분위수 교차이다. 넷 다 조건 간 비교가 아니라 자료 자체의 성질을 재는 기술적 측정이며 추적기에 대해 아무 주장도 하지 않는다. 다만 성격이 같지는 않다 — 분산비와 분위수 교차는 원고에 이미 적혀 있던 문장을 사후에 검증하려고 낸 것이고, 둘 다 그 문장을 철회시켰다. MOT17-13 진단은 저장소 기록에 탐색으로 표시되어 있다. 어느 것도 판정에 쓰이지 않았으나, “실험은 전부 사전 등록되었다”는 서술은 이 넷을 빼고서만 참이다.

다중 비교에 대해서는 다음과 같다. 초기 사전 등록 문서를 대상으로 세었을 때 평가지표 52개, 사전 점검 27개였다(이후 실험이 추가되었으므로 실제 개수는 이보다 많다). 유의수준 0.05를 기준으로 하면 우연히 유의해질 것으로 기대되는 개수는 2.6개이다. 그러나 이 문턱은 본 연구의 검정에 맞지 않는다. 유의성을 확보한 둘은 모두 $n = 7$ 부호검정이고 그 최소 p 가 0.0156이므로(4.5절), 같은 문턱에서 세면 기대 개수는 $52 \times 0.0156 = 0.81$ 이다. 즉 관측된 2건은 우연 기대의 약 2.5배이다. 이 계산은 부호검정 계열에만 해당한다. 표본이 수만 건인 검출 수준 지표는 0.0156보다 훨씬 낮은 p 에 도달할 수 있어 같은 문턱으로 묶이지 않는다.

유의성을 확보한 결과는 둘이다. 박스 크기 모형이 검출별 공분산 모형을 이긴 것(7/7, 음의 방향)과 합친 모형이 박스 크기 모형을 이긴 것(7/7, 양의 방향, 5.2절). 후자는 양의 방향이므로 다중 비교의 영향을 받으며, 본 연구는 그 효과가 -0.012 nats로 첫 번째의 1/47에 불과하다는 점을 근거로 실용적 함의를 주장하지 않는다.

연구 과정에서 18건의 결론을 철회하였으며, 이를 삭제하지 않고 원인과 함께 기록으로 남겼다. 그중에는 라이브러리 가로채기 과정의 좌표계 오류, 난수 시드 미고정, 사전 등록된 절차를 따르지 않은 값으로 판정한 사례 등이 포함된다. 특히 세 번째 경우에는 올바른 절차로 다시 측정하였을 때 결과의 부호가 반대로 나왔다. **마지막 두 건은 본 원고를 작성하는 과정에서 발생하였다.** 하나는 6.2절에 측정 없이 방향을 예측한 문장이고, 다른 하나는 부록 C가 주변부 AUC 0.4661을 “박스가 작을수록 연관이 틀리기 쉽다”는 방향으로 옮겨 적은 것이다. 둘 다 사후에 측정하여 철회하였다. 뒤의 것은 개정 과정에서 5.7절 논증의 전제로 승격되었다가 잡혔다. 자기 논증의 전제로 삼기 전에 그 전제를 재야 한다. 원고의 문장도 자료와 같은 검사를 받아야 한다.

추적기 재생은 결정적이며, 동일 조건을 다시 실행하여 출력 파일의 해시가 7개 시퀀스 전부에서 일치함을 확인하였다. 다만 MOT17 데이터는 CC BY-NC-SA 3.0 라이선스로 재배포가 불가능하므로, 실험의 완전한 재현은 데이터를 직접 확보한 경우에만 가능하다. 이론 부분의 코드는 이러한 제약 없이 실행 가능하다.

부록 A

조건별 통제와 남은 취약점

앞의 두 절이 낸 음의 결과에 대해 가장 먼저 제기되는 반론은 “ σ 조건만 제대로 조율하지 않은 것 아닌가”이다. 이 절은 각 경로에 어떤 통제를 두었는지 모아 적고, 그럼에도 남은 약점을 그대로 기록한다.

각 경로에 남은 취약점 개별 경로에는 다음과 같은 약점이 있다. 결론을 뒤집지는 않으나 그 자체로 기록해 둔다.

- 거리 함수 — 사전 등록 경계에 0.02 차이로 근접하였다. 사전 등록 문서는 “박스 크기 조건이 -5.0 보다 나쁘면 추정 방식 비교를 해석하지 않는다”는 조건을 미리 적어 두었다. 실측값이 -4.98 이었으므로 0.02만 달랐다면 본 연구는 3.93이라는 격차를 해석할 수 없었다. 시퀀스 간 표준편차가 중앙값 2.60인 것에 비하면 이 조건의 통과 여부는 사실상 우연에 가까웠다. 이 취약성을 명시한다. 다만 격차의 존재 자체가 이 사전 등록 조건에 좌우되지는 않는다 — 격차가 같은 대조(거리 함수에서 DFL 대 박스 크기)를 별도의 재생 코드와 별도의 스케일 적합으로 다시 채워 3.651을 냈고 (표 5.4), 그 값은 이 사전 등록 조건과 무관하게 산출된다. 두 값이 일치한다는 뜻이 아니라 부호와 자릿수가 같다는 뜻이며, 검출 캐시는 두 파이프라인이 공유하므로 완전히 독립인 재현도 아니다.
- 거리 함수 — 손실의 대부분이 설명되지 않는다. 원 격차 -10.56 가운데 임계값 효과가 2.6을 설명하여 -7.96 이 남고, 여기서 정규화와 추정 방식을 함께 바꾸면 약 3.0이 회복되어 -4.98 이 된다. 나머지 약 5.0은 설명되지 않은 채 남는다. 다만 그 3.0은 두 가지를 동시에 바꾼 결과이므로 정규화만의 기여로 귀속할 수 없다. 본 연구는 이를 분포 유사도라는 의미론이 이 문제에 맞지 않는 부분으로 보지만 그것은 측정이 아니라 해석이다.
- 게이팅 — 확장이 채택을 넓히는 개입이 아니다. 확장량을 키우면 1단계 채택률이 오를 것으로 가정하였으나, 실험데이터 7개 시퀀스의 연관 호출 7,314회를 기록하여 같은 입력에 α 만 바꾸어 재생한 결과 채택 쌍 수는 α 에 단조가 아니었다. $\alpha = 5$ 에서 +35쌍으로 정점에 이른 뒤 감소하여 $\alpha = 20$ 에서 -165 쌍이었다. 본 실험이 사용한 $\alpha = 10$ 은 그 전환점 위에 있어 채택 쌍 수가 기준선과 같았다(변화 +0쌍). 다만 채택 집합은 1.92%(884쌍)가 달라졌으므로 개입이 작동하지 않은 것은 아니다. 개수가 같을 뿐 어느 쌍이 채택되는지가 바뀌었다. 따라서 이 경로를 “게이트를 넓히는 완화”로 서술할 근거는 없다. (-4.33 이라는 값 자체는 유효하나, 그 손실을 하나의 비율로

귀속하는 서술은 표 B.1에서 철회하였다.) 또한 이 재생은 확장을 하지 않은 궤적이 방문한 호출들에서의 반사실이므로, $\alpha = 10$ 실행이 실제로 그 구간에 머물렀는지는 별개의 문제이다. 쌍별 확장량 불일치는 중앙값 0.64로 합성 장면(0.24)의 2.6배였다.

- 매칭 임계값 — 이 실험은 검정력이 낮다. 오라클 이득이 7개 시퀀스 중 5개에서 $+0.20 \sim +0.65$ 로 잡음 수준이며, MOT17-13의 최적 임계값은 탐색 격자의 끝에 남아 있다 — 즉 오라클 여지 $+0.892$ 가 과소평가될 수 있다.
- 칼만 필터 — 통제되지 않은 설정이 있다. 저자 코드를 재현하였으나 NSA 계수 적용 여부(`nsa`) 등 일부 설정을 통제하지 않았고 1회만 실행하였다. -0.62 라는 작은 효과에 대해서는 이것이 살아 있는 교란이다.
- 잡음 대조군이 없다. σ 조건의 손실 가운데 얼마가 “ σ 가 틀린 정보를 준다”이고 얼마가 “비용 행렬을 교란하면 무엇이든 손해다”인지 분리되지 않았다. 5.5절도 이 역할을 하지 못한다. 그 실험이 넣은 “검출별 스칼라”는 임의의 값이 아니라 σ 를 프레임 안에서 $[0, 1]$ 로 표준화한 것이기 때문이다. σ 를 프레임 안에서 뒤섞는 대조군을 생각할 수 있으나, 트랙이 검출의 분산을 물려받아 짝 일관성이 깨지므로 타당하지 않다고 판단하였다. 따라서 본 연구에는 잡음 대조군이 없고 대안도 찾지 못하였다. 다만 5.7절의 행 조건부 측정은 이 교란을 우회한다. 같은 호출 안의 두 검출을 비교하므로 “비용을 교란하면 손해”라는 설명이 적용되지 않는다.

경로별로 무엇을 통제하였는가 위 취약점들과 별개로, 각 경로에 실제로 둔 통제는 다음과 같다.

- 검출: 모든 조건이 비트 단위로 동일한 캐시를 재생한다. 성능 차이에 검출 변동이 섞일 여지가 없다(3.2절).
- 거리 함수: 비용 분포가 달라지면 채택률이 변하므로, 각 조건의 스케일 상수를 기준선과 채택률이 일치하도록 이분 탐색으로 맞추었다. 또한 위치 향의 크기 정규화 여부를 갈라 두 조건을 모두 측정하였다. 주 조건(정규화 판본)은 자료를 보기 전에 정하였다. 실제로 DFL에서는 정규화하지 않은 쪽이 더 나았으므로(4.2절), 결과를 보고 고른 것이 아니다.
- 게이팅: σ 조건과 총 확장량이 같은 박스 크기 조건을 나란히 두었다. 따라서 차이를 “확장했는가”가 아니라 “확장량을 무엇으로 정했는가”로 귀속할 수 있다.
- 매칭 임계값: 기준선의 임계값이 이미 최적에 가깝다는 것을 전역 탐색으로 확인하였다(아래). 즉 기준선이 불리하게 설정되어 있지 않다.
- 칼만 필터: 저자 공개 코드의 절차를 재현하였다.

남은 한계는 추정 방식이 경로마다 다르다는 점이다(표 5.3) — 칼만 필터와 게이팅은 NMS 후보 분산을, 거리 함수는 DFL 분포 분산을 사용한다. 이는 각 경로에서 선행 연구

가 사용한 추정 방식을 따랐기 때문이나, 그 결과 경로와 추정 방식이 완전히 뒤엎힌다. 엄밀히 말해 각 음의 결과는 “그 경로가 나쁘다”와 “그 경로에 쓴 추정 방식이 나쁘다”를 구별하지 못한다. 게이팅 경로에는 한 겹이 더 있다 — σ 조건과 대조군을 무엇으로 맞추는가에 따라 격차가 -8.5 에서 $+0.2$ 까지 움직이며(표 B.1), 주 기준인 채택률 일치는 NMS 후보 분산에 대조군 자체가 존재하지 않는다. 본 연구가 분리한 것은 경로 안에서의 추정 방식뿐이다. 거리 함수에서 검출기 σ 대 박스 크기(-8.90 대 -4.98), 게이팅에서 검출기 σ 대 박스 크기(3.81 차이). 두 경로 모두에서 같은 방향이지만 2×2 설계는 아니다(7.3절 한계 (1)).

임계값 경로에는 애초에 여지가 거의 없다 전역 최적 임계값은 기본값 대비 $+0.037$ 에 불과하였다. 시퀀스별 최적값은 $0.70 \sim 0.98$ 로 갈리지만, 정답을 알고 시퀀스마다 최적값을 선택해도 여지가 $+0.892$ 이다. 장면 관측량으로 예측하는 규칙은 -0.207 이었다.

이 경로에서 가중 여부로 부호가 뒤집힌다. 비가중 시퀀스 평균으로는 예측 규칙이 $+0.249$, 오라클 여지가 $+1.491$ 이다(가중 값은 각각 -0.207 , $+0.892$). 4.5절에서 언급한 “부호가 뒤집힌 두 번” 중 하나가 바로 이 경로이다. 다만 두 값 모두 절댓값이 0.3 미만이고 시퀀스별 부호검정도 $5/7$ ($p = 0.453$)로 미결이므로, 어느 집계를 쓰든 “이 규칙은 이득을 내지 못한다”는 판정은 같다. 사전 등록한 주 판정은 가중 결합이다.

부록 B

게이팅 대조군의 맞춤 기준

게이팅 경로의 대조군 — 귀속은 무엇을 맞추었는가에 달려 있다 이 경로의 손실은 두 조각으로 나뉜다. 박스를 키우는 것 자체는 거의 비용이 들지 않는다(-0.52). 그런데 확장량을 σ 가 결정하도록 하면 기준선 대비 -4.33 이 된다. 격자에서도 같은 방향이다. 박스 크기로 확장하면 $+0.074$ 로 사실상 공짜인데(표 5.4), 검출기 σ 로 확장량을 정하면 진다.

그러나 그 격차를 하나의 비율로 귀속할 수는 없다. 본 연구는 이전 판에서 “손실의 88%가 확장량을 무엇으로 정했는가에서 온다”고 적었으나, 이 서술을 철회한다. 세 가지 맞춤 기준으로 같은 격차를 다시 측정하였더니 부호가 같았기 때문이다(표 B.1, 그림 B.1). 88%라는 수치는 “평균 선형 확장량을 맞춘다”는 선택의 산물이었으며, 그 선택은 사전에 정당화된 적이 없다.

더 근본적으로, 주 기준은 적용 자체가 불가능하였다. 거리 함수 경로가 쓰는 기준 — 채택률 일치 — 를 게이팅에 옮기려면 NMS 후보 분산으로 박스 크기 조건의 채택률 (0.9692)에 도달해야 하는데, 이 추정 방식의 채택률은 $\alpha = 2$ 에서 0.9639 로 정점에 이른 뒤 감소하므로 어떤 확장량으로도 도달하지 못한다. 즉 채택률을 맞춘 대조군은 이 조합에 대해 존재하지 않는다. 이는 격자에서 같은 조합을 “개입 불성립”으로 판정한 것과 같은 사실을 다른 기준으로 확인한 것이다.

다만 이 수치에는 유보가 둘 붙으며, 본 연구는 이를 잠정적인 것으로 취급한다. 첫째, 격자가 이 대조를 교차 검증하지 못한다. 격자에서 NMS 후보 분산 $\times$ 게이팅은 개입이 성립하지 않아 값을 쓸 수 없기 때문이다(표 5.4). 둘째, 확장이 채택을 넓히는 개입임을 검증한 구간이 실제로 사용한 구간이 아니다. 방향 검사는 $\alpha = 2$ 의 합성 장면에서 수행되었고 본 실험은 $\alpha = 10$ 의 실데이터이다. 확장을 검출과 트랙 양쪽에 주면 합성 장면에서 $\alpha = 40$ 까지 단조로 채택이 넓어지는 것을 확인하였으나(정답쌍 비용 $0.460 \rightarrow 0.246$, 게이트 통과율 $2.21\% \rightarrow 4.47\%$), 실데이터에서 확인한 것은 아니다. 확장을 검출에만 주면 같은 장면에서 통과율이 2.21% 에서 0.05% 로 무너지므로, 확장을 어느 쪽에 주는가가 개입의 방향 자체를 바꾼다(7.4절).

다섯 칸 가운데 넷이 음수이고 하나가 양수이며, 값의 범위가 8.735 HOTA로 본 연구의 최소 검출 가능 효과(3.31)의 두 배가 넘는다. 사전 등록된 판정 규칙은 부호가 같리면 귀속을 철회하도록 정해 두었다. 다만 부호를 가른 $+0.191$ 은 해상도의 $1/17$ 이므로 “DFL이 이겼다”로 읽지 않는다. 읽을 수 있는 것은 맞춤 기준을 바꾸면 격차가 8.7 HOTA만큼 움직인다는 사실이며, 그것만으로 하나의 비율에 귀속하는 서술은 지탱되지 않는다.

표 B.1: 맞춤 기준에 따른 검출기 σ - 박스 크기 (게이팅 경로, HOTA). 박스 크기 조건 ($\alpha = 0.5$)을 앵커로 삼고 각 기준의 값을 맞추었다. “불능”은 측정 실패가 아니라 그 대조군이 존재하지 않는다는 뜻이다. NMS 후보 분산의 채택률은 $\alpha = 2$ 에서 0.9639로 정점에 이르므로 목표 0.9692에 도달할 수 없다.

맞춘 양	NMS 후보 분산	DFL 분포 분산
평균 선형 확장량 (px)	-7.630	-1.947
총 확장 면적	-8.543	-2.034
1단계 채택률 (주 기준)	불능	+0.191




그림 B.1: 게이팅 경로에서 검출기 σ 와 박스 크기의 격차는 무엇을 맞추었는가에 달려 있다(표 B.1을 그림으로 옮긴 것). 같은 대조를 세 가지 맞춤 기준으로 다시 재면 DFL 계열은 0을 가로지른다. 사전 등록한 주 기준(채택률 일치)에서 NMS 후보 분산은 점이 없는데, 이는 측정 실패가 아니라 그 대조군이 존재하지 않기 때문이다. 채택률이 $\alpha = 2$ 에서 0.9639로 정점에 이르러 목표 0.9692에 닿지 못한다. 회색 띠는 최소 검출 가능 효과 ± 3.31 이고, 값의 범위 8.735는 그 2.6배이다.

부록 C

장면 간 산포에 대해 시험한 가설

가설: 시퀀스 간 σ 스케일 차이 — 기각 3.5절에서 카이제곱 배율이 시퀀스마다 62 ~ 1840배로 갈린다고 하였으므로, 시퀀스를 합쳐 하나의 순위로 세우면 스케일 차이가 순위를 지배해 시퀀스 안의 판별력이 가려질 수 있다고 보았다. 이를 확인하기 위해 시퀀스 안에서 순위 정규화한 뒤 합쳐 AUC를 다시 계산하였다. 결과는 0.5355 $\rightarrow$ 0.5480으로 거의 변하지 않았다.

원인을 다시 확인해 보니 전제부터 틀렸다. 3.5절의 62 ~ 1840배는 $z^2 = \epsilon^T \Sigma_d^{-1} \epsilon$ 의 배율이므로 σ 뿐 아니라 실제 오차 ϵ 에도 의존한다. σ 자체의 시퀀스 간 차이를 별도로 측정하면 채택된 쌍의 중앙값이 0.235 ~ 0.441로 약 2배에 불과하다. 순위 정규화가 아무 것도 바꾸지 못한 것은 당연한 결과였다. 이 가설은 기각한다.

AUC를 크기로 읽으면 무엇이 달라지는가 사전 등록된 판정 기준(AUC < 0.55)은 방향성 기준이었다. 그런데 AUC는 0.5를 중심으로 대칭이어서 0.457과 0.543은 같은 크기의 정보이고 부호는 규칙을 어느 방향으로 세울지만 정한다. 따라서 0.4571은 “ σ 가 클수록 오류”라는 가설을 반증하지만, 그 자체로 “정보가 없다”를 뜻하지는 않는다. $|AUC - 0.5|$ 로 보면 DFL이 0.043, NMS가 0.036이다.

그럼에도 “ σ 에 쓸 만한 역방향 신호가 있다”고 읽어서는 안 된다. 두 가지 근거가 있다. 첫째, 박스 크기 기반 σ_C 역시 0.4661로 0.5 아래이므로 0.5를 벗어난 부분은 검출기 불확실성이 아니라 기하학적 성질로 설명된다. 다만 이것을 “박스가 작을수록 틀린다”는 방향으로 옮겨 적어서는 안 된다 — 두 분포가 교차하므로 0.4661은 이동이 아니라 교차의 요약이다(5.7절). 둘째, 박스 높이를 통제된 편상관이 -0.0220으로 사실상 0이다. 크기 효과를 제거하면 남는 것이 없다. 본 절의 결론은 이 둘째 근거에 실린다. 첫째는 방향을 주장하지 않고 “검출기 σ 에 귀속되지 않는다”만 말한다.

남는 관찰 MOT17-04의 AUC가 0.897로 두드러지는데, 이 시퀀스는 수정 가능한 오류가 141건으로 가장 적다. 오류 수로 가중한 평균은 0.5603으로 단순 중앙값 0.6275보다 낮아지므로, 시퀀스별 값이 높은 쪽에 오류가 적게 몰려 있다. 그러나 이것이 원인인지 우연인지는 장면 7개로는 가릴 수 없다(6.5절). AUC와 개선 여지 사이의 상관을 보았으나 $\rho = -0.571$, $p = 0.180$ 으로 유의하지 않았고 DFL에서는 부호가 반대(+0.429)여서 근거로 쓰지 않는다.

참고문헌

- Bae, S.-H., & Yoon, K.-J. (2014). Robust online multi-object tracking based on tracklet confidence and online discriminative appearance learning. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1218–1225.
- Bewley, A., Ge, Z., Ott, L., Ramos, F., & Upcroft, B. (2016). Simple online and realtime tracking. *IEEE International Conference on Image Processing (ICIP)*, 3464–3468.
- Bergmann, P., Meinhardt, T., & Leal-Taixé, L. (2019). Tracking without bells and whistles. *IEEE/CVF International Conference on Computer Vision (ICCV)*, 941–951.
- Bolya, D., Foley, S., Hays, J., & Hoffman, J. (2020). TIDE: A general toolbox for identifying object detection errors. *European Conference on Computer Vision (ECCV)*.
- Cao, J., Pang, J., Weng, X., Khirodkar, R., & Kitani, K. (2023). Observation-centric SORT: Rethinking SORT for robust multi-object tracking. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9686–9696.
- Du, Y., Zhao, Z., Song, Y., Zhao, Y., Su, F., Gong, T., & Meng, H. (2023). StrongSORT: Make DeepSORT great again. *IEEE Transactions on Multimedia*, 25, 8725–8737.
- Kuhn, H.W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1–2), 83–97.
- Lee, C.W., & Waslander, S.L. (2024). UncertaintyTrack: Exploiting detection and localization uncertainty in multi-object tracking. *IEEE International Conference on Robotics and Automation (ICRA)*, 4946–4953. arXiv:2402.12303.
- Li, X., Wang, W., Hu, X., Li, J., Tang, J., & Yang, J. (2021). Generalized Focal Loss V2: Learning reliable localization quality estimation for dense object detection. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 11627–11636.
- Luiten, J., Ošep, A., Dendorfer, P., Torr, P., Geiger, A., Leal-Taixé, L., & Leibe, B. (2021). HOTA: A higher order metric for evaluating multi-object tracking. *International Journal of Computer Vision*, 129(2), 548–578.
- Meng, T., Fu, C., Huang, M., Wang, X., He, J., Huang, T., & Shi, W. (2025). Localization-Guided Track: A deep association multi-object tracking framework based on localization confidence of detections. *IEEE Sensors Journal*, 25, 5282–5293. (본 연구가 읽은 판본은 arXiv:2309.09765, 2023이다.)

- Miah, M., Bilodeau, G.-A., & Saunier, N. (2023). Multi-object tracking and segmentation with a space-time memory network. *Conference on Robots and Vision (CRV)*, 184–193. arXiv:2110.11284.
- Milan, A., Leal-Taixé, L., Reid, I., Roth, S., & Schindler, K. (2016). MOT16: A benchmark for multi-object tracking. *arXiv:1603.00831*. (MOT17은 별도 논문이 없고 MOT16과 같은 영상에 검출과 주석을 보강한 판본이므로, 관례에 따라 이 문헌으로 인용한다.)
- Solano-Carrillo, E., Sattler, F., Alex, A., Klein, A., Costa, B.P., Rodriguez, A.B., & Stoppe, J. (2024). UTrack: Multi-object tracking with uncertain detections. *European Conference on Computer Vision Workshops (ECCVW), Uncertainty Quantification for Computer Vision*. Lecture Notes in Computer Science, 219–236. arXiv:2408.17098.
- Somers, V., Standaert, B., Joos, V., Alahi, A., & De Vleeschouwer, C. (2025). CAMELTrack: Context-aware multi-cue exploitation for online multi-object tracking. *arXiv:2505.01257*.
- Sun, P., Cao, J., Jiang, Y., Yuan, Z., Bai, S., Kitani, K., & Luo, P. (2022). DanceTrack: Multi-object tracking in uniform appearance and diverse motion. *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- Wang, J., Ancha, S., Chen, Y.-T., & Held, D. (2020). Uncertainty-aware self-supervised 3D data association. *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. arXiv:2008.08173.
- Wang, J., Xu, C., Yang, W., & Yu, L. (2021). A normalized Gaussian Wasserstein distance for tiny object detection. *arXiv:2110.13389*.
- Wojke, N., Bewley, A., & Paulus, D. (2017). Simple online and realtime tracking with a deep association metric. *IEEE International Conference on Image Processing (ICIP)*, 3645–3649.
- Yi, K., Luo, K., Luo, X., Huang, J., Wu, H., Hu, R., & Hao, W. (2024). UCMCTrack: Multi-object tracking with uniform camera motion compensation. *AAAI Conference on Artificial Intelligence*, 38, 6702–6710.
- Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W., & Wang, X. (2022). ByteTrack: Multi-object tracking by associating every detection box. *European Conference on Computer Vision (ECCV)*. Lecture Notes in Computer Science, 1–21.